Производительность языка Rust

Work in progress

Об авторах

Юрий Грибов (yugr, the_real_yugr), https://github.com/yugr

- Разработчик и фанат системного ПО (компиляторов, рантаймов, инструментов верификации и т. п.)
- Руководитель компиляторной команды

Захар Акимов, https://github.com/z-inform

- Разработчик general-purpose и AI компиляторов

Особенности языка Rust

- Язык для высокопроизводительного системного программирования
  - Zero cost/overhead abstractions: don’t pay for what you don’t use + no (or minimal) runtime overhead (итераторы, closures, traits, etc.)
  - Возможность низкоуровневого тюнинга (SIMD, inline assembler, компиляторные интринсики типа __builtin_expect, etc.)
- Поддерживает современные парадигмы программирования
  - Процедурное, функциональное и объектно-ориентированное программирование
  - Статический и динамический полиморфизм
  - Etc.
- Язык сокращает количество видов UB за счёт более строгих правил и динамических проверок
  - Особенно memory safety

Производительность Rust: Минусы

- Проверки в рантайме
- Обязательная инициализация
- Компромиссы между производительностью и надёжностью в стандартной библиотеке
  - Устойчивость к некорректным компараторам, DoS-стойкое хэширование и т.д.
- Отсутствие -ffast-math
- Допустимость signed integer overflows
- ...

Производительность Rust: Плюсы

- Больше возможностей для alias analysis
  - По сути restrict-by-default
- Агрессивные оптимизации структур
  - Оптимизация порядка полей и niche optimizations
- Более эффективные стандартные контейнеры
- …

Цели доклада

https://pxhere.com/ru/photo/870592

- Насколько “дороги” проверки Rust на практике ?
  - В сравнении с Rust без проверок и C/C++
  - Каковы непосредственные (лишние инструкции) и вторичные (влияние на другие оптимизации, давление на I$/BTB) последствия проверок
- Способен ли от них избавиться Sufficiently Smart (Heroic) Compiler © ?
- И если нет, то как с ними может справиться программист ?
- Есть ли какие-то особенности языка которые наоборот помогают компилятору ?

Мнение создателей языка

- Steven Klabnik:
  - "Generally Rust is the same order of magnitude as C. Sometimes faster, sometimes slower”
  - “Rust prioritizes memory safety above all else. But speed is a close second"

Анализ накладных расходов

- Как оценить накладные расходы от проверок ?
- В компиляторах Rust нет флагов для отключения проверок безопасности
- Мы сравним обычный Rust и пропатченный Rust с отключенными проверками
  - Репозиторий с модифицированными версиями компилятора: yugr/rust-private
  - Базовая ветка yugr/baseline основана на теге 1.87.0
    - Для стабильности измерений отключена рандомизация хэштаблиц и усилено выравнивание функций

Бенчмарки

- Набор бенчмарков компилятора Rust
- Внутренние бенчмарки крупных open-source проектов из разных областей:
  - Gamedev (Bevy, Veloren)
  - Базы данных (SpacetimeDB)
  - Работа с текстом (Zed, Ruff, regex)
  - Кодеки (rav1e, oxipng)
  - Линейная алгебра (nalgebra)
  - Асинхронный runtime (tokio)
  - Пакетные менеджеры (uv)
- Многие бенчмарки уже были сильно оптимизированы (с помощью unsafe и т.п.)

Rust и C++

- Rust и C++ близки по выразительным возможностям:
  - Поддержка нескольких парадигм программирования (процедурной, ООП и функциональной)
  - Статический и динамический полиморфизм
  - Etc.
- Область применения языков совпадает (высокопроизводительное системное программирование)
  - Zero cost/overhead abstractions
  - Возможность низкоуровневого тюнинга
- Те же backend-оптимизаторы (LLVM, GCC) и технологии оптимизации (PGO, LTO, etc.)
- А также покажем оверхед от аналогичных проверок в “безопасном” диалекте C++ (Hardened C/C++)

Чего не будет в докладе: Другие аспекты языков

- Эргономичность, выразительность (в частности self-referential data structures), безопасность, etc.
- На эти темы есть множество других докладов !
  - Rust Features that I Want in C++ (CppNow 2022)
  - Rust vs C++ with Steve Klabnik and Herb Sutter (SW Engineering Daily podcast)
  - The existential threat against C++ and where to go from here (NDC 2024)

Чего не будет в докладе: Параллельный код

- Одним из преимуществ Rust считается простота написания корректного параллельного кода
  - Fearless Concurrency with Rust
- Тема требует отдельного рассмотрения и глубокой экспертизы
  - C++ Russia 2027 anyone ?

Чего не будет в докладе: Неидиоматичный код

- Наша цель – “типичный” код на Rust
  - Без SIMD или компиляторных интринсиков, inline assembler, unsafe (в том числе get_unchecked и wrapping_add), restrict, etc.
  - Стандартная библиотека
    - Возможно это ограничение слишком избыточное: Rust поощряет и упрощает использование внешних библиотек
- С помощью unsafe, etc. (и большого количества времени) всегда можно добиться идентичной производительности Rust и эквивалентного C++

Чего не будет в докладе: Неидиоматичный код

- Nikita Popov, lead-мэйнтэйнер LLVM:
  - “Languages like C, C++ and Rust are by-design on equal footing“
  - “You can only compare how easy it is to write performant code or how performant idiomatic code is”
- Scott McMurray, Rust compiler team:
  - “Clang and rustc are both producing LLVM IR and running mostly the same LLVM optimization passes”
  - “Given enough work they can always produce essentially the same thing, making the comparisons pointless”

Bounds checks

Детальный разбор

Переполнения буфера

- Morris Worm (1988)
- Запись чрезмерно большого объёма данных в переменную программы

```
char local_buf[32];
sprintf(buf, “Message from user: %s”, received_data);
```

- Переполнение стека (stack overflow)
  - Атаки Stack Smashing, Return-to-libc, Return-Oriented Programming
  - Наиболее стандартизованный и технологичный вид атак
- Переполнение кучи (heap overflow)

https://www.rawpixel.com/image/5958324/free-public-domain-cc0-photo

Распространённость buffer overflow уязвимостей

- Лидирующие позиции в рейтинге наиболее опасных уязвимостей
  - Mitre CWE Top 25 2024 (места 2, 6, 20)
- 70% уязвимостей в продуктах Microsoft и Chromium вызваны ошибками памяти
- 40% атак, вызванных ошибками работы с памятью, вызваны buffer overflow
  - Google Project Zero (2024)
- 80% Memory Safety CVE и 46% Memory Safety KEV в 2024
  - 20%+ из них это stack overflow (наиболее опасная уязвимость)
  - Не лучшая метрика (большая часть CVE это уязвимости веб-приложений)

Memory safety в Rust

- Фронтенд генерирует проверки стандартных индексных доступов
  - Массивы, slices, контейнеры, etc.
  - Проверки могут быть удалены если оптимизатор может доказать безопасность
- Также используются более безопасные алгоритмы в стандартной библиотеке
  - Например сортировка не упадёт при использовании некорректного компаратора

https://www.picpedia.org/highway-signs/s/safety.html

Накладные расходы

- Выполнение сравнения и условного перехода (2 или более тактов)
- Дополнительный регистр для хранения длины для сравнения
- Давление на I$ (промахи в кэш) из-за кода проверки и обработчика паники
- Давление на BTB (branch mispredictions)
  - Adding a (predictable) branch to existing code can increase branch mispredictions (Daniel Lemire)
    - 2-4 кратный рост mispredictions из-за *predictable* ветвления
  - Любители LeetCode знают что resize + operator[] работает быстрее чем push_back (push-dominoes)
- Отключение других оптимизаций
  - Прежде всего векторизатора

Оптимизации в компиляторе

- Во многих случаях компилятор способен
  - Гарантировать корректность доступа и удалить проверки
  - Или вынести проверки из цикла (O(N) -> O(1))
- Эти оптимизации делаются на уровне LLVM
  - InstCombine, SimpleLoopUnswitch, LoopVectorize, etc.
  - Также должны оптимизировать Hardened C/C++
- Оптимизатор был сильно улучшен и многие проблемы прошлых лет успешно оптимизируются в текущей версии Rust
  - Например известные примеры Алекса Кладова (matklad)

Успешная оптимизация

Все проверки вынесены в пролог функции

```rust
#[no_mangle]
pub fn foo(a: &[i32], b: &[i32]) -> i32 {
    let mut ans = 0;
    let n = a.len();
    for i in 0..n {
        ans += a[i] * b[i];
    }
    ans
}
```

```
foo:
        .cfi_startproc
        test    rsi, rsi
        je      .LBB0_1   // n == 0 => вернуть 0
        lea     rax, [rsi - 1]
        cmp     rcx, rax
        jbe     .LBB0_6   // b.len() < n => паника
        xor     eax, eax
        xor     ecx, ecx
        .p2align        4
.LBB0_4:                  // Цикл (без проверок!)
        mov     r8d, dword ptr [rdx + 4*rcx]
        imul    r8d, dword ptr [rdi + 4*rcx]
        lea     r9, [rcx + 1]
        add     eax, r8d
        mov     rcx, r9
        cmp     rsi, r9
        jne     .LBB0_4
...
```

Использовались флаги
-Cno-vectorize-loops
-Cno-vectorize-slp
-Cllvm-args=-unroll-allow-remainder=0

Неуспешная оптимизация

Проверки остались в цикле

```rust
#[no_mangle]
pub fn foo(v: &[i32]) -> i32 {
    let mut ans = 0;
    let chunk_len = 4;
    let num_chunks = v.len() / chunk_len;
    for i in 0..num_chunks {
        for j in 0..chunk_len {
            ans += v[i * chunk_len + j];
        }
    }
    ans
}
```

Использовались флаги
-Cno-vectorize-loops
-Cno-vectorize-slp
-Cllvm-args=-unroll-allow-remainder=0

```
bar:
        ...
        .p2align        4
.LBB0_2:        // Цикл (с проверками!)
        lea     rcx, [r8 - 3]
        cmp     rcx, rsi
        jae     .LBB0_7
        lea     rcx, [r8 - 2]
        cmp     rcx, rsi
        jae     .LBB0_7
        lea     rcx, [r8 - 1]
        cmp     rcx, rsi
        jae     .LBB0_7
        cmp     r8, rsi
        jae     .LBB0_6
        add     eax, dword ptr [rdi + 4*r8 - 12]
        add     eax, dword ptr [rdi + 4*r8 - 8]
        add     eax, dword ptr [rdi + 4*r8 - 4]
        add     eax, dword ptr [rdi + 4*r8]
        add     r8, 4
        dec     rdx
        jne     .LBB0_2
```

Проблемы в оптимизаторе: delayed panics

- В Rust RFC 560 было предложено разрешить компилятору комбинировать вместе связанные проверки
  - Если это полезно для оптимизации
  - И поведение программы не изменится (с точностью до сообщения об ошибке)
- Похоже на классическую концепцию Imprecise Exceptions
- Решение о допустимости подобных оптимизаций пока не принято и в случае индексных проверок эта оптимизация сейчас не делается ☹
- Пример: rust #50759

```
use std::fs::{read, write};

fn main() -> Result<(), std::io::Error> {
    let h = read("/tmp/test")?;
    // Каждый доступ проверяется отдельно ☹
    // (достаточно было бы проверить h[15])
    let b = [h[0], h[1], ... h[15]];
    write("/tmp/test", &b)?;
    Ok(())
}
```

Workarounds: Общие соображения

- В циклах используйте слайсы, а не контейнеры
  - Это упрощает работу alias analysis
  - Пример: fschutt/fastblur #3
- Избегайте сложной индексной арифметики
  - На практике всё что сложнее прибавления константы или сложения двух индексных переменных
  - Даже аффинные операции: Taking Advantage of Auto-Vectorization in Rust
- В нетривиальных случаях избегайте полагаться на оптимизатор
  - Его возможности могут (немонотонно) меняться в разных версиях компилятора
  - “Auto-vectorization is not a programming model”
- Эти же советы актуальны и для Hardened C/C++ !

Workarounds

- Удаление проверок
- Сокращение числа проверок
- Снижение стоимости проверок

Workarounds

- **Удаление проверок**
- Сокращение числа проверок
- Снижение стоимости проверок

Workarounds: Unsafe-код

- Наиболее простое и надёжное решение
- Используется внутри контейнеров и итераторов стандартной библиотеки
- Несколько вариантов:
  - Использование указателей в unsafe-блоках
  - Различные варианты get_unchecked для отключения проверки
  - Хинты для компилятора core::hint::unreachable_unchecked и core::hint::assert_unchecked
- Пример: [rust #36072]

```
    /// Return a reference to the element at `index`.
    ///
-   /// Panics if the index is out of bounds.
-   ///
-   /// Unsafe because index must not equal pos.
-   #[inline(always)]
+   /// Unsafe because index must be within the data slice and not equal to pos.
+   #[inline]
    unsafe fn get(&self, index: usize) -> &T {
        debug_assert!(index != self.pos);
-       &self.data[index]
+       debug_assert!(index < self.data.len());
+       self.data.get_unchecked(index)
    }
```

Workarounds: Использование ограниченных типов

- Ограниченность индекса можно выразить с помощью типов
  - Enums или bool
- Пример: rust #102303

```rust
fn foo(array: &[i16; 3],
       i: usize) -> i16 {
    array[i]
}
```

→

```rust
pub enum Enum {
    A, B, C
}

fn foo(array: &[i16; 3],
       i: Enum) -> i16 {
    array[i as usize]
}
```

Workarounds

- Удаление проверок
- **Сокращение числа проверок**
- Снижение стоимости проверок

Workarounds: Ручные asserts

- Позволяет сделать однократную проверку вместо нескольких
- Пример: [jpeg-decoder #167]

```
+     // optimizer hint to eliminate bounds checks within loops
+     assert!(coefficients.len() == 64);
+
      let mut temp = [Wrapping(0); 64];


      // columns
      for i in 0..8 {
          if coefficients[i + 8] == 0
              && coefficients[i + 16] == 0
              && coefficients[i + 24] == 0
              && coefficients[i + 32] == 0
              && coefficients[i + 40] == 0
              && coefficients[i + 48] == 0
              && coefficients[i + 56] == 0
          {
```

Workarounds: Итераторы

- Многие итераторы используют информацию о размере контейнера для сокращения числа проверок

```
pub fn foo(x: &mut [i32], y: &[i32]) {
    let n = x.len();
    for i in 0..n {
        x[i] ^= y[i];
    }
}
```

```
.LBB1_2:
  cmp rcx, rax
  je  .LBB1_5
  mov r8d, dword ptr [rdx + 4*rax]
  xor dword ptr [rdi + 4*rax], r8d
  lea r8, [rax + 1]
  mov rax, r8
  cmp rsi, r8
  jne .LBB1_2
```

```
pub fn foo(x: &mut [i32], y: &[i32]) {
    x.iter_mut()
        .zip(y.iter())
        .for_each(|(x, y)| *x ^= *y);
}
```

```
.LBB0_7:
  mov edi, dword ptr [rcx + 4*rsi]
  xor dword ptr [rdx + 4*rsi], edi
  inc rsi
  cmp rax, rsi
  jne .LBB0_7
```

Компиляция с
-Cno-vectorize-loops

Недостатки итераторов

- “Miracle of zero cost abstraction has a limit" (fridsun at Reddit)
- Сильное разбухание и замедление debug-кода
- Компилятор может не заинлайнить длинные цепочки итераторов
- Лямбды в итераторах принимают ссылки на элементы, что может вызывать проблемы с LLVM alias analysis (rust #106539)
- Chained-итераторы (chain, flat_map, flatten, etc.) генерируют неэффективный код при использовании в for-циклах (“external iteration”)
  - Рекомендуется их применять только с .for_each (“internal iteration”)
  - Are iterators even efficient?

Workarounds: Reslicing

- Reslicing, preslicing или subslicing
- Раннее конструирование слайсов заданного размера
- Заставляет компилятор сделать *однократную* проверку при создании слайса
- Пример: [dropbox/rust-brotli]

```
for i in 0..vec.len() {
    black_box(vec[i]);
}
```

```
let slice = &vec[..vec.len()];
for i in 0..vec.len() {
    black_box(slice[i]);
}
```

Workarounds

- Удаление проверок
- Сокращение числа проверок
- **Снижение стоимости проверок**

Workarounds: Арифметика вместо проверок

- Проверки можно заменить на инструкцию conditional move

```
let i = cmp::min(i, sums.len());
sums[i] = ...
```

- CMOV *как правило* быстрее чем бранч
- Недостаток: ошибка не будет обнаружена и программа продолжит работу

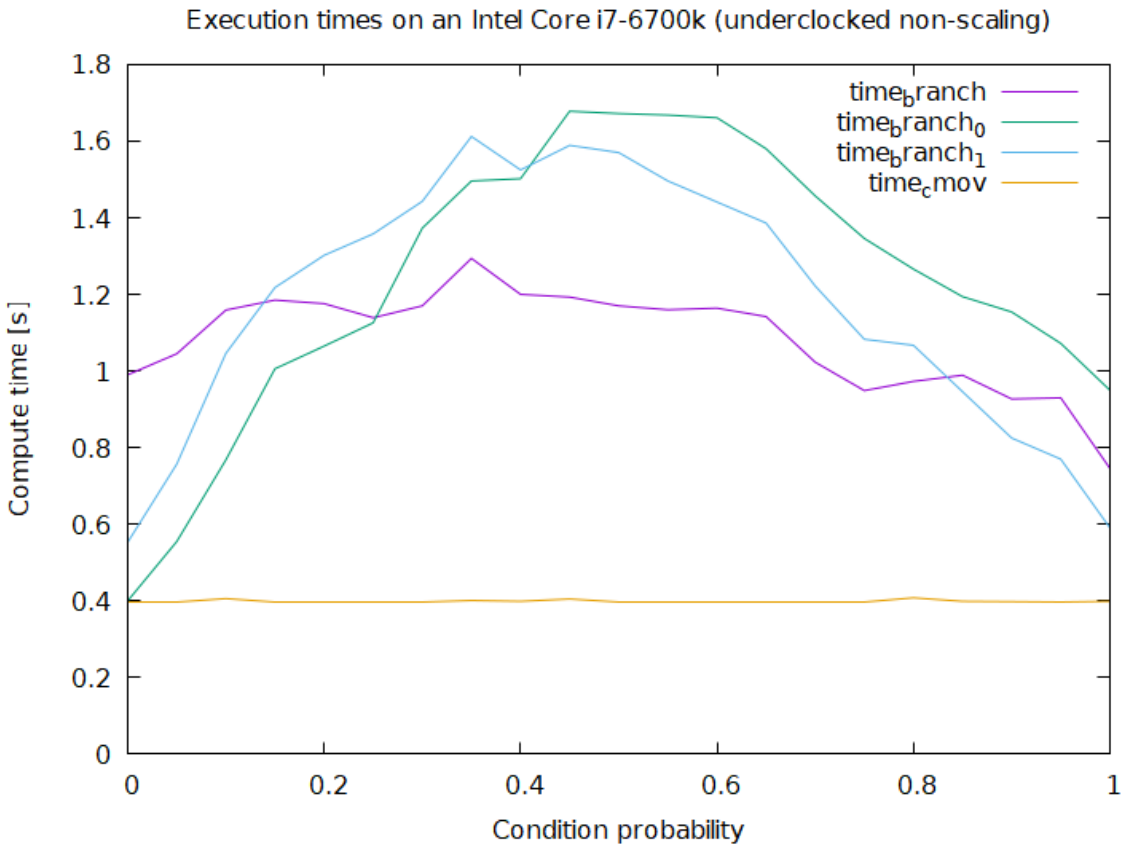

https://github.com/marcin-osowski/cmov

Распространённость

- Более **20%** вызовов panic handlers в librustc_driver.so (ядро компилятора Rust) вызваны индексными проверками
  - Данные получены на основе анализа бинарного кода
- Отключение индексных проверок сокращает число внутренних циклов с panic handlers **в 5 раз**
  - Данные получены с помощью LLVM плагина на основе анализа rustc и oxipng

Методика анализа

Ветка компилятора

Рост производительности при отключении проверок

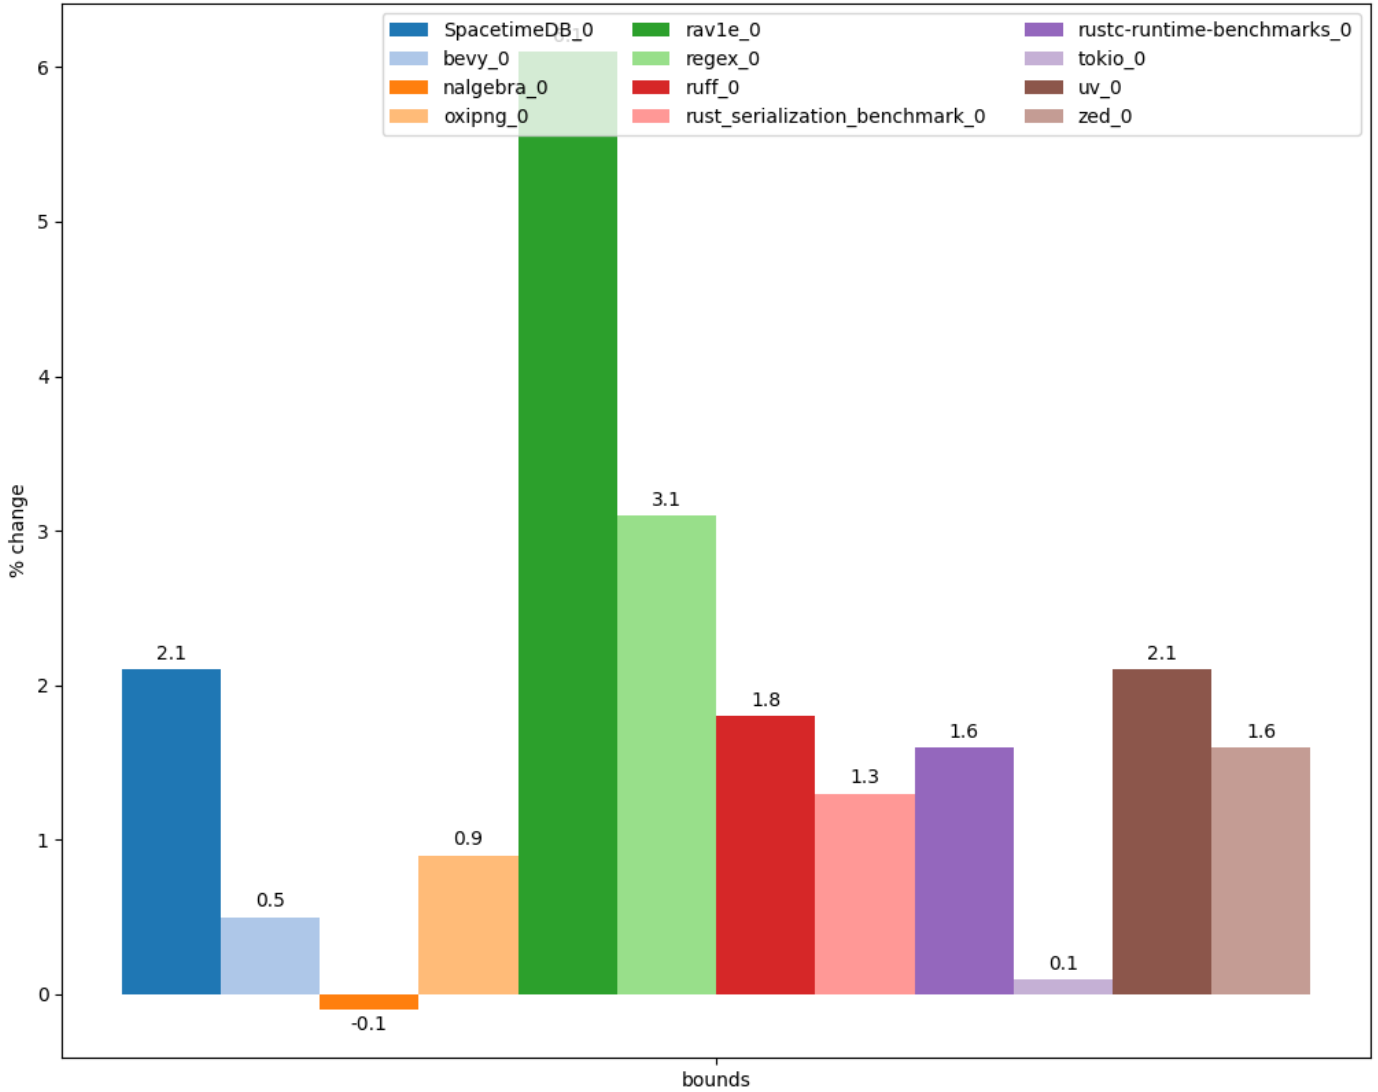

Отключалась инструментация в пользовательском коде и проверки в стандартной библиотеке (контейнеры, slices, strings, etc.)

Ветка компилятора

Hardened C/C++

- В C/C++ доступны ограниченные решения для обеспечения memory safety:
  - StackProtector
  - _FORTIFY_SOURCE
  - Hardened STL (C++ only)
  - -fsanitize=bounds, -fsanitize=object-size
- Полную проверку корректности индексов сделать невозможно из-за отсутствия информации о диапазонах для raw pointers
  - Например только 20% нетривиальных обращений в память в коде Clang могут быть проверены
  - C++ Safe Buffers может быть решением, но требует нетривиальной модификации кода
- Дополнительная информация:
  - Hardening: текущий статус и перспективы развития

Mario Simoes, https://snl.no/Mount_Everest

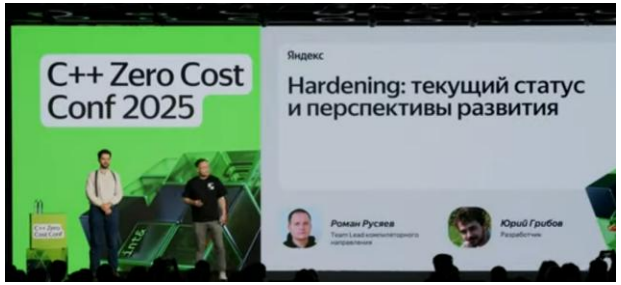

Rust vs. Hardened C++

```rust
#[no_mangle]
pub fn foo(x: &[i32], i: usize) -> i32 {
    x[i]
}
```

rustc -O -Cpanic=abort

```
foo:
        cmp     rdx, rsi
        jae     .LBB0_2
        mov     eax, dword ptr [rdi + 4*rdx]
        ret
.LBB0_2:
        push    rax
        lea     rax, [rip +
.Lanon.acbd18db4cc2f85cedef654fccc4a4d8.1]
        ...
call    qword ptr [rip +
_ZN4core9panicking18panic_bounds_check@GOTPCREL]
```

```chinese_quotes_replace_with_ascii_quotes
#include <span>

extern “C”
int foo(std::span<int> s, size_t i) {
  return s[i];
}
```

gcc -O2 -D_GLIBCXX_ASSERTIONS

```
foo:
.LFB821:
        cmp     rdx, rsi
        jnb     .L7
        mov     eax, DWORD PTR [rdi+rdx*4]
        ret
.L7:
        sub     rsp, 8
        ...
        call
_ZSt21__glibcxx_assert_failPKciS0_S0_@PLT
```

Накладные расходы в C++

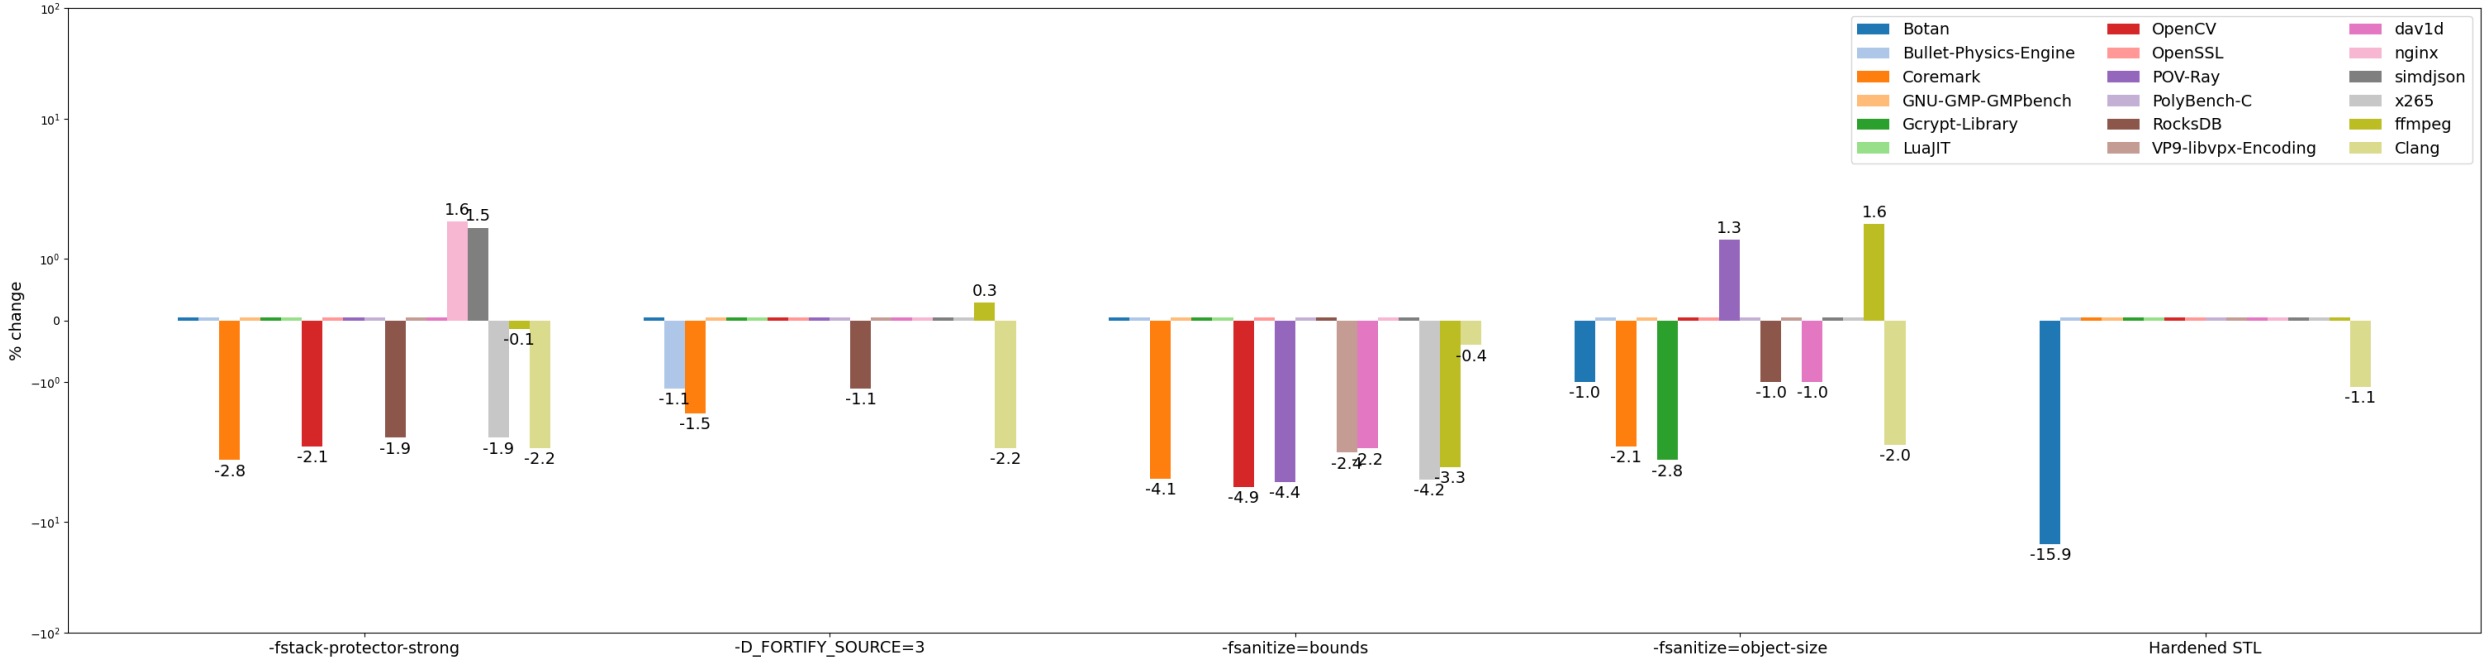

Неожиданные улучшения производительности связаны с аномалиями оптимизатора (неудачной векторизацией, отменой инлайнинга, etc.)

Выводы

- Проверки индексов в Rust применяются более агрессивно чем в Hardened C/C++
  - В Hardened C/C++ можно проверить в 5 раз меньше доступов чем в Rust
- Накладные расходы в среднем могут достигать 3-4% (и сравнимы с Hardened C/C++)
  - Но отдельные тесты могут замедляться на десятки процентов (как впрочем и в Hardened C/C++)
- Существует множество способов избежания проверок в критических частях кода
  - Некоторые из них будут не нужны если решат проблему с delayed panics (rust #50759)

Правила алиасинга

Детальный разбор

Алиасинг указателей

- Универсальная концепция в языках программирования
- Могут ли два разных указателя (ссылки) в программе адресовать одну и ту же память ?
- В разных языках приняты различные подходы:
  - Никакие два указателя в программе не могут ссылаться на одни и те же данные (например Fortran 77)
  - Любые указатели могут ссылаться на одни и те же данные (например ранние версии языка C)
  - Промежуточные варианты
    - Например strict (type-based) aliasing в C89 и restrict-аннотации в C99

Почему важен алиасинг ?

- Неограниченный алиасинг удобен для программиста, но снижает возможности компилятора
- Отсутствие алиасинга даёт больше возможностей многим оптимизациям
  - Векторизация, CSE, GVN, LICM, DSE, etc.
- Поэтому важнейшим компонентом любого компилятора является модуль Alias Analysis
  - Идентификация указателей, которые могут (или не могут) алиаситься

```c
int alias(int *a, int *b) {
  *a = 0;
  *b = 1;
  return *a;
}

int noalias(int * restrict a, int * restrict b) {
  *a = 0;
  *b = 1;
  return *a;
}
```

```asm
alias:
  mov     DWORD PTR [rdi], 0
  mov     DWORD PTR [rsi], 1
  mov     eax, DWORD PTR [rdi]
  ret

noalias:
  mov     DWORD PTR [rdi], 0
  xor     eax, eax
  mov     DWORD PTR [rsi], 1
  ret
```

Теория алиасинга

- Точный внутрипроцедурный alias analysis
  - NP-полон в отсутствие динамических аллокаций (Pointer-induced aliasing, 1991)
  - Неразрешим иначе (Undecidability of static analysis, 1992)
- В реальных программах алиасинг встречается очень редко
  - 98% указателей в бенчмарках SPEC ссылаются только на один объект
    - Dynamic Points-To Sets (Mock et al., 2001)
- Существующие Alias Analysis консервативно переоценивают алиасинг в 1.5-20 раз
  - Dynamic Points-To Sets (Mock et al., 2001)
  - Speculative Alias Analysis for Executable Code (Fernandez et al., 2002)
  - ORAQL — Optimistic Responses to Alias Queries in LLVM (Doerfert et al., 2023)

Алиасинг в Rust

- Правила Borrow checker влияют на производительность:
  - Mutable-ссылка не может алиаситься ни с какими другими (mutable или shared) ссылками
  - Mutable-ссылка, пока она существует, является единственным указателем на объект
  - Объект, адресуемый shared-ссылкой, не может быть изменён (пока она существует)
- На практике это позволяет добиться функциональности, сходной с restrict в C/C++

```
pub fn foo(a: &mut i32,
           b: &mut i32) -> i32 {
    *a = 0;
    *b = 1;
    *a
}
```

```
define i32 @foo(
  ptr noalias ... %a,
  ptr noalias ... %b) {
    store i32 0, ptr %a
    store i32 1, ptr %b
    ret i32 0
}
```

```
foo:
    mov     dword ptr [rdi], 0
    mov     dword ptr [rsi], 1
    xor     eax, eax
    ret
```

Ограничения

- Информация об указателях предоставляется с помощью атрибута noalias у аргументов функций
  - Ссылки, возникающие *внутри* функций, никак не помечаются и с точки зрения LLVM могут алиаситься
- Решение возможно с помощью alias.scope metadata, но пока не реализовано (#16515)
- Workaround: создание dummy-функции для генерации noalias-аннотаций
  - Пример: rustc

```rust
pub fn foo(a: *mut i32,
           b: *mut i32) -> i32 {
    let a = unsafe { &mut *a };
    let b = unsafe { &mut *b };
    *a = 1;
    *b = 2;
    *a
}
```

```asm
foo:
    mov     dword ptr [rdi], 1
    mov     dword ptr [rsi], 2
    mov     eax, dword ptr [rdi]
    ret
```

Ограничения

- Частный случай указанной выше проблемы – алиасинг ссылок на элементы структур данных
- Например при передаче в функцию двух векторов компилятор не сможет определить что их буферы не алиасятся
- Workaround: передавать в функции raw slices

```
pub fn foo(a: &mut Vec<i32>,
           b: &Vec<i32>) {
    let n = a.len();
    let b = &b[..n];
    for i in 0..n {
        a[i] = b[i] + 100;
    }
}
```

```
pub fn foo(a: &mut [i32],
           b: &[i32]) {
    let n = a.len();
    let b = &b[..n];
    for i in 0..n {
        a[i] = b[i] + 100;
    }
}
```

Эффективность правил алиасинга Rust

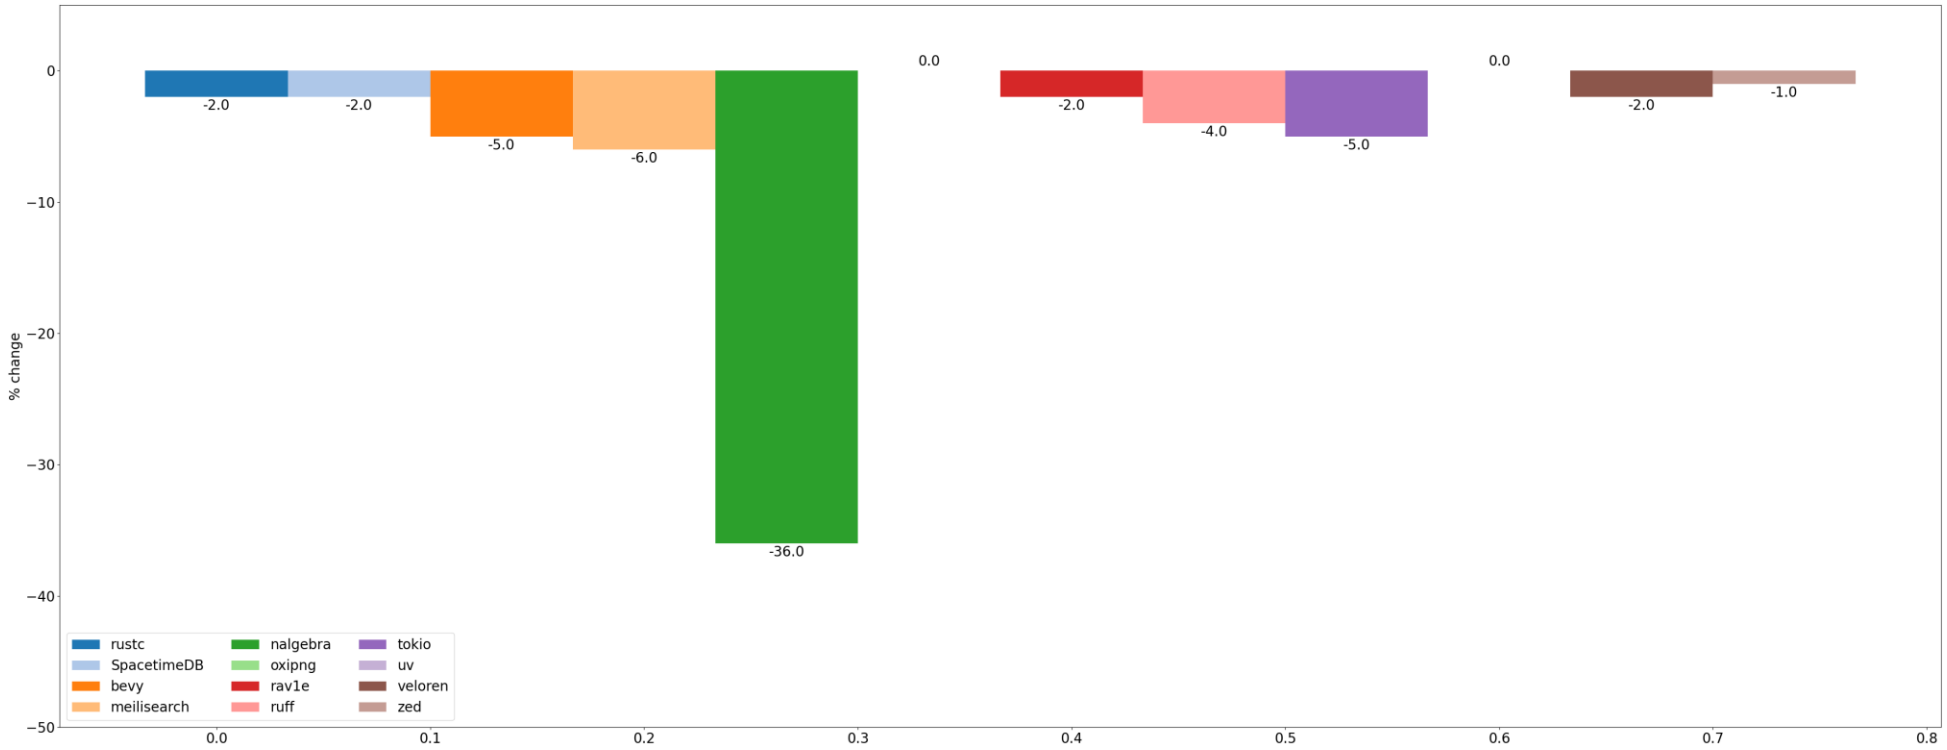

Точность алиас-анализа – число пар указателей, для которых анализ смог дать чёткий ответ (MustAlias / NoAlias)

Ухудшение точности Alias Analysis в Rust при отключении правил алиасинга

Методика анализа Ветка компилятора

Ухудшение производительности при отключении правил алиасинга

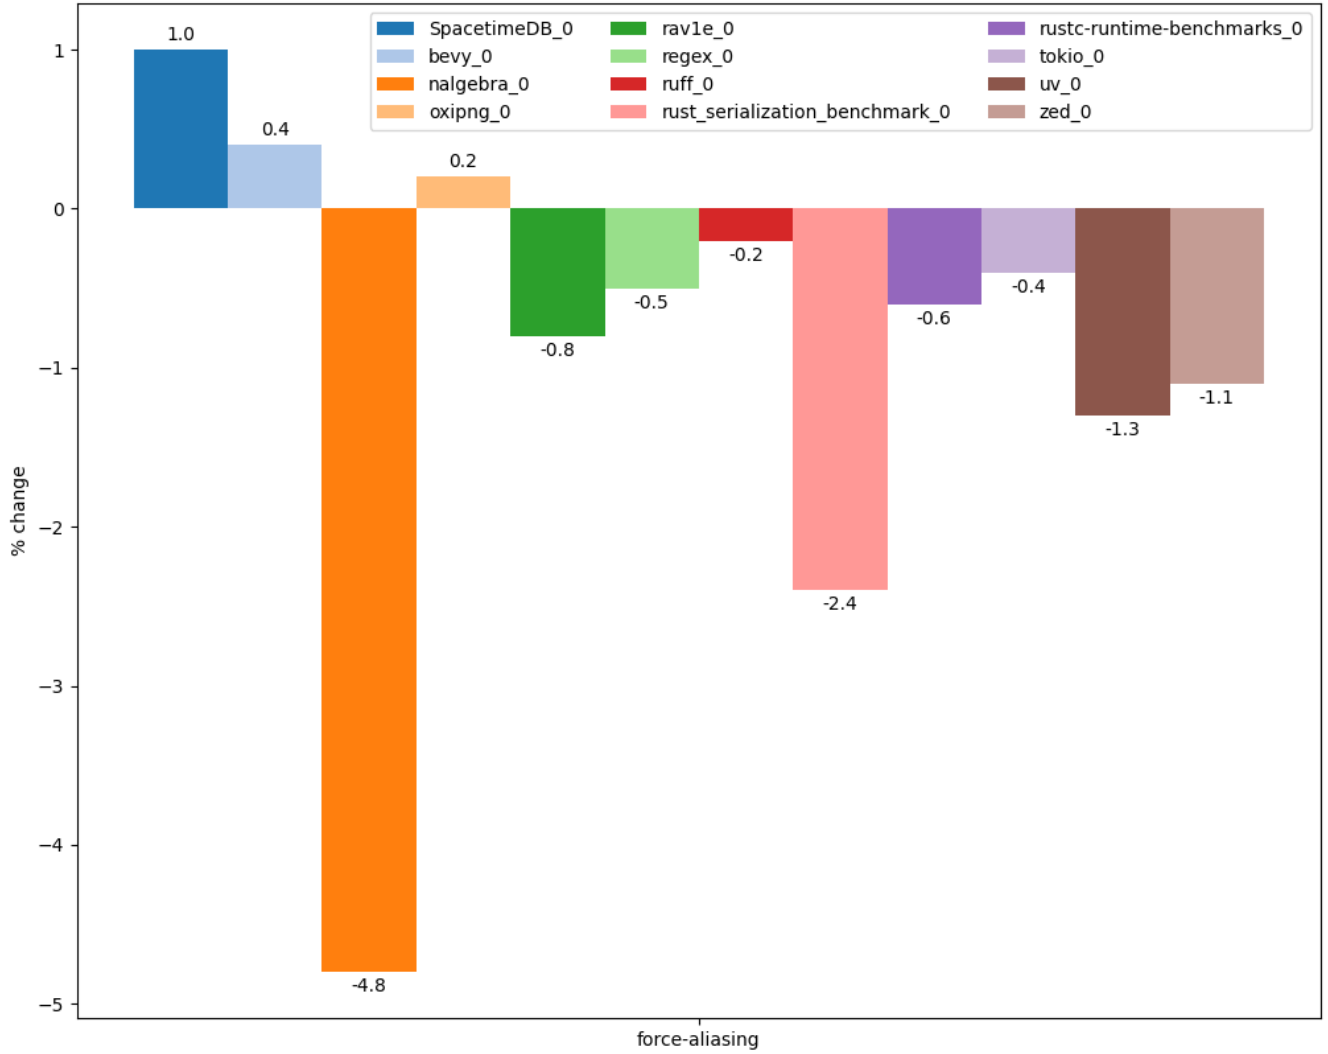

Ветка компилятора

Ситуация в C/C++

- C и C++ запрещают алиасинг указателей на разные типы
  - Кроме char *, signed/unsigned, scalar/vector и т.п.
- Но многие проекты игнорируют это правило (с помощью -fno-strict-aliasing)
- C и C++ предоставляют возможность явного запрета алиасинга программистом с помощью ключевого слова restrict
  - На практике эта функциональность используется редко (в Rust долго не могли включить правила aliasing из-за скрытых багов в LLVM)

Выводы

- Правила алиасинга в Rust позволяют
  - Повысить точность анализа *в среднем* на 5%
  - Улучшить производительность на 1-4%
- После решения проблемы с aliasing metadata в rust #16515 можно ожидать существенного прироста производительности

Обязательная инициализация

Детальный разбор

Обязательная инициализация

- Неинициализированные переменные приводят к утечкам данных и другим ошибкам
  - Утечки паролей и адресов (утечка адреса компрометирует защиту ASLR)
- Распространённость:
  - 10% CVE root cause в продуктах Microsoft в 2018 (из Killing Uninitialized Memory)
  - 12% exploitable багов в Android (из P2723)

Пример

```
void foo() {
  char password[32];
  ...
}
void bar() {
  char message[1024];
  if (cond) strcpy(message, "...");
  // Сливаем пароль если !cond
  printf(message);
}
void baz() {
  foo();
  bar();
}
```

Подход Rust

- Поэтому Rust требует инициализации всех переменных
- Переменная должна присваивается на всех путях до первого использования

```
pub fn foo() {
  let x = 10;
  x
}
```

OK

```
pub fn foo(cond: bool) -> i32 {
  let mut x;
  if cond {
    x = 10;
  } else {
    x = 20;
  }
  x
}
```

OK

```
pub fn foo(cond: u32) -> i32 {
  let mut x;
  if cond > 10 {
    x = 10;
  } else if cond <= 10 {
    x = 20;
  }
  x
}
```

NOT OK

Другие языки

- Многие другие языки также требуют инициализацию от программиста (или предоставляют автоинициализацию нулями):
  - C#, Swift, Go, Java
  - Hardened C/C++ (-ftrivial-auto-var-init), C++26 (P2795)
    - Включены по умолчанию в Android user/kernel-space и Chrome
    - Только локальные переменные (глобальные переменные и sbrk/mmap-буферы уже инициализируются, а для кучи нужен hardened allocator)

Проблема с обязательными инициализациями

- Во многих случаях обязательные инициализации излишни
  - Буду перезаписаны другими значениями в дальнейшем
- Компилятор не всегда может удалить ненужные инициализации
- Пример:

```
let mut file = File::open("example.bin")?;

while (...) {
    let mut buffer = [0u8; 1024];  // memset not removed

    let n = file.read(&mut buffer)?;

    ...
}
```

Распространённость лишних инициализаций

- Сколько ненужных инициализаций приходится делать ?
- Статическая оценка (с помощью LLVM-плагина count-stores):
  - Hardened Clang: +4% stores, 11x вызовов memset (!) в циклах Clang
- Динамическая оценка на примере rustc и clang (с помощью Valgrind-плагина DeadWrites):
  - Компиляция oxipng с помощью rustc:
    - 9% неиспользуемых записей
  - Компиляция LICM.ii с помощью Clang:
    - 11% неиспользуемых записей
  - То же с помощью Hardened Clang (-ftrivial-auto-var-init):
    - 23% неиспользуемых записей (2x !)

Накладные расходы

- К сожалению измерить накладные расходы от лишних инициализаций в наших Rust-бенчмарках невозможно
  - Так как потребовалась бы значительная модификация кода
- Проиллюстрируем накладные расходы на примере
  - Сообщений от пользователей
  - Замеров Hardened C/C++

Накладные расходы в Rust

- Какие последствия могут иметь лишние инициализации для производительности ?
  - 7% в stdlib file IO (rust #26950)
  - 20-30% в Hyper HTTP (комментарий в tokio #1744)
  - 30% в симуляторе Shadow (shadow #1643)
  - 25% в stdlib TcpStream (RFC #837)
  - 1.5% в rav1d (Making the rav1d Video Decoder 1% Faster)

Накладные расходы при включении компиляторных инициализаций (на примере C++)

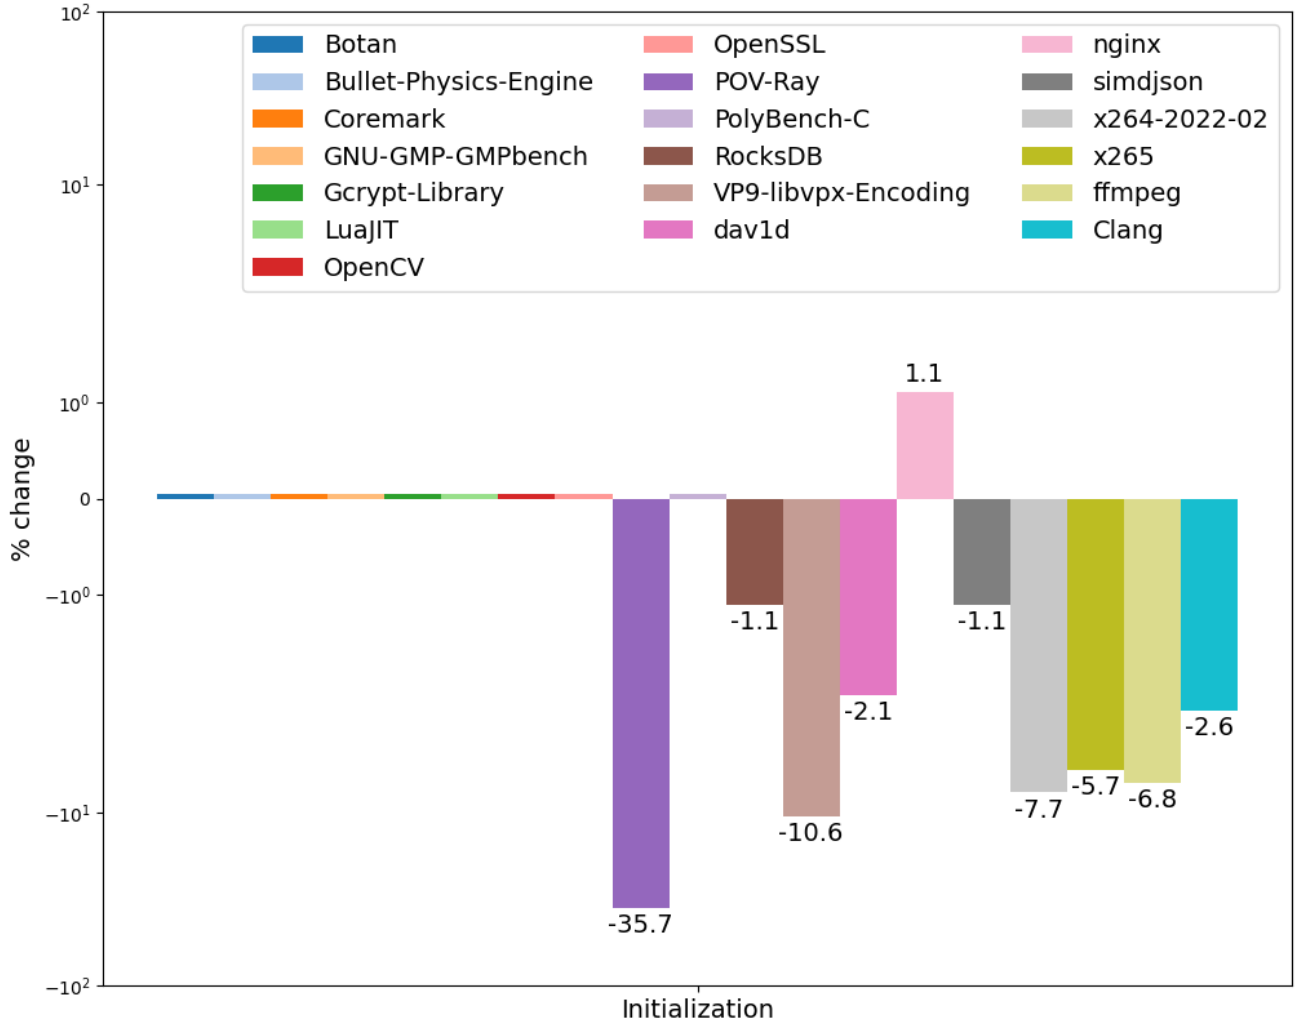

Оптимизации в компиляторе

- Инициализации скалярных переменных очень дёшевы и оптимизируются многими SSA-проходами в LLVM
  - DCE, BDCE, ADCE, InstCombine, etc.
- Оптимизации сохранений в память представляют наибольшую проблему
  - DSE (DeadStoreElimination), MoveAutoInit, MemCpyOptimizer
  - В меньшей степени InstCombine

Workarounds

- К сожалению API для работы с неинициализиованной памятью в Rust (MaybeUninit) не очень эргономичны
- Нельзя просто создать ссылку на неинициализированный массив и потом заполнить его:

  “Creating a reference with &/&mut is **only allowed if** the pointer is properly aligned and **points to initialized data**” (addr_of_mut)

Workarounds: Стандартные типы

Массивы:

```
let buf :: [u8; 4] = unsafe {
    let mut buf = MaybeUninit::<[u8;
4]>::uninit();
    let ptr = buf.as_mut_ptr();
    for i in ... {
        ptr.offset(i).write(...);
    }
    buf.assume_init()
};
```

Структуры:

```
let role :: Role = unsafe {
    let mut uninit =
MaybeUninit::<Role>::uninit();
    let ptr = uninit.as_mut_ptr();
    // Нужна именно запись
    // (а не присваивание)
    // чтобы не пытаться удалить
    // неинициализированный String
    addr_of_mut!((*ptr).name)
        .write("basic".to_string());
    (*ptr).flag = 1;
    (*ptr).disabled = false;
    uninit.assume_init()
};
```

Workarounds: Векторы

```
let mut buf = Vec<u8>::new();

let old_len = buf.len();
buf.reserve(data.len());

unsafe {
    let ptr = buf.spare_capacity_mut();
    for i in ... {
        ptr[idx].write(...);
    }
    buf.set_len(len + data.len());
}
```

Workarounds: IO

```
let mut buf = [MaybeUninit::uninit(); 4096];
let mut buf = BorrowedBuf::from(&mut buf[..]);
rd.read_buf(buf.unfilled())?;
if buf.len() == 0 {
    break Ok(());
}
// Можно использовать buf.filled()
```

Выводы

- Накладные расходы от дополнительной инициализации локальных переменных в Rust, Hardened C++ и C++26 сопоставимы
  - Возможно больше в Rust, т.к. там инициализируется и динамическая память
- Эти расходы могут быть достаточно большими в некоторых сценариях (>10%) и требовать ручного тюнинга кода:
  - Использование специальных библиотечных API (типа MaybeUninit и других)

Локализация символов

Детальный разбор

Локализация символов

- Функции, объявленные в единице трансляции (крейт в Rust, cpp-файл в C++), могут быть локальными для неё или глобальными
  - В C/C++ контролируется с помощью static или anonymous namespaces
  - В Rust с помощью pub(crate) или pub(super)
- В Rust и C++ выбраны противоположные решения о дефолтном поведении:
  - В Rust функции по умолчанию локальны для своего модуля (top-level функции – для своего крейта)
  - pub(crate)-функции видимы в пределах своего крейта
  - pub-функции видны в пределах всей программы

Локализация в Rust

```rust
#[inline(never)]  // Simulate inliner fail
pub(crate) fn foo1(x: i32) {
    println!("Hello world {}", x);
}

mod mymod {
    #[inline(never)]  // Simulate inliner fail
    pub(super) fn foo2(x: i32) {
        println!("Goodbye world {}", x);
    }

    #[inline(never)]  // Simulate inliner fail
    pub fn foo3(x: i32) {
        println!("Nice world {}", x);
    }
}

pub use mymod::foo3;

pub fn bar() {
    foo1(1);
    mymod::foo2(2);
    mymod::foo3(3);
}
```

```
$ rustc +baseline test.rs -O --emit=asm
--crate-type=rlib -o- \
    | rustfilt \
    | grep globl
        .globl  test::mymod::foo3
        .globl  test::bar
```

Экспортируются только foo3 и bar !

Оптимизации в компиляторе

- Локальные функции лучше оптимизируются компилятором
- Как правило такие оптимизации связаны с изменением API или ABI:
  - Межпроцедурное распространение констант (IPSCCP)
  - Замена передачи по ссылке на передачу по значению (ArgumentPromotion)
  - Удаление мёртвых аргументов или возвращаемых значений (DeadArgumentElimination)
  - Релаксация calling convention (замена на coldcc в Transforms/IPO/GlobalOpt.cpp)
  - Межпроцедурная аллокация регистров (IPRA)
- А также
  - Более агрессивный inlining (например всегда инлайнятся однократно вызываемые локальные функции)
  - Улучшенное обнаружение мёртвого кода

Пример оптимизации

```rust
#[inline(never)]  // Simulate inliner fail
fn foo(b: bool, seed: i32, s: &[i32]) -> i32 {
    let mut ans = seed;
    for &x in s {
        ans += if b { 1 } else { ans ^ x }
    }
    ans
}

pub fn bar(n: i32, s: &[i32]) -> i32 {
    let mut ans = 0;
    for i in 0..n {
        ans += foo(true, i, s);
    }
    ans
}
```

```asm
foo:
        lea     eax, [rsi + rdi]
        ret
```

Цикл в foo был полностью оптимизирован

Сравнение с C/C++

- Многие авторитетные руководства рекомендуют локализовывать функции:
  - Google C++ Style Guide
  - LLVM Coding Standard (Restrict Visibility)
  - C++ Core Guidelines
  - Chromium C++ Style Guide
- Слабым местом C++ является невозможность локализовать private-методы классов
  - Попытка такой оптимизации

Распространённость

- Сколько локальных функций в реальных программах на Rust ?
  - 80-90%
  - (Для сбора статистики отключалась локализация с помощью патча)
- В C/C++ результаты сильно зависят от проекта:
  - 80-90% (clang, ffmpeg, git, opencv, bitcoin)
  - 40-50% (openssl, tmux, gcc, libuv)
  - (Для сбора статистики использовалась утилита Localizer)

Замедление при отключении локализации

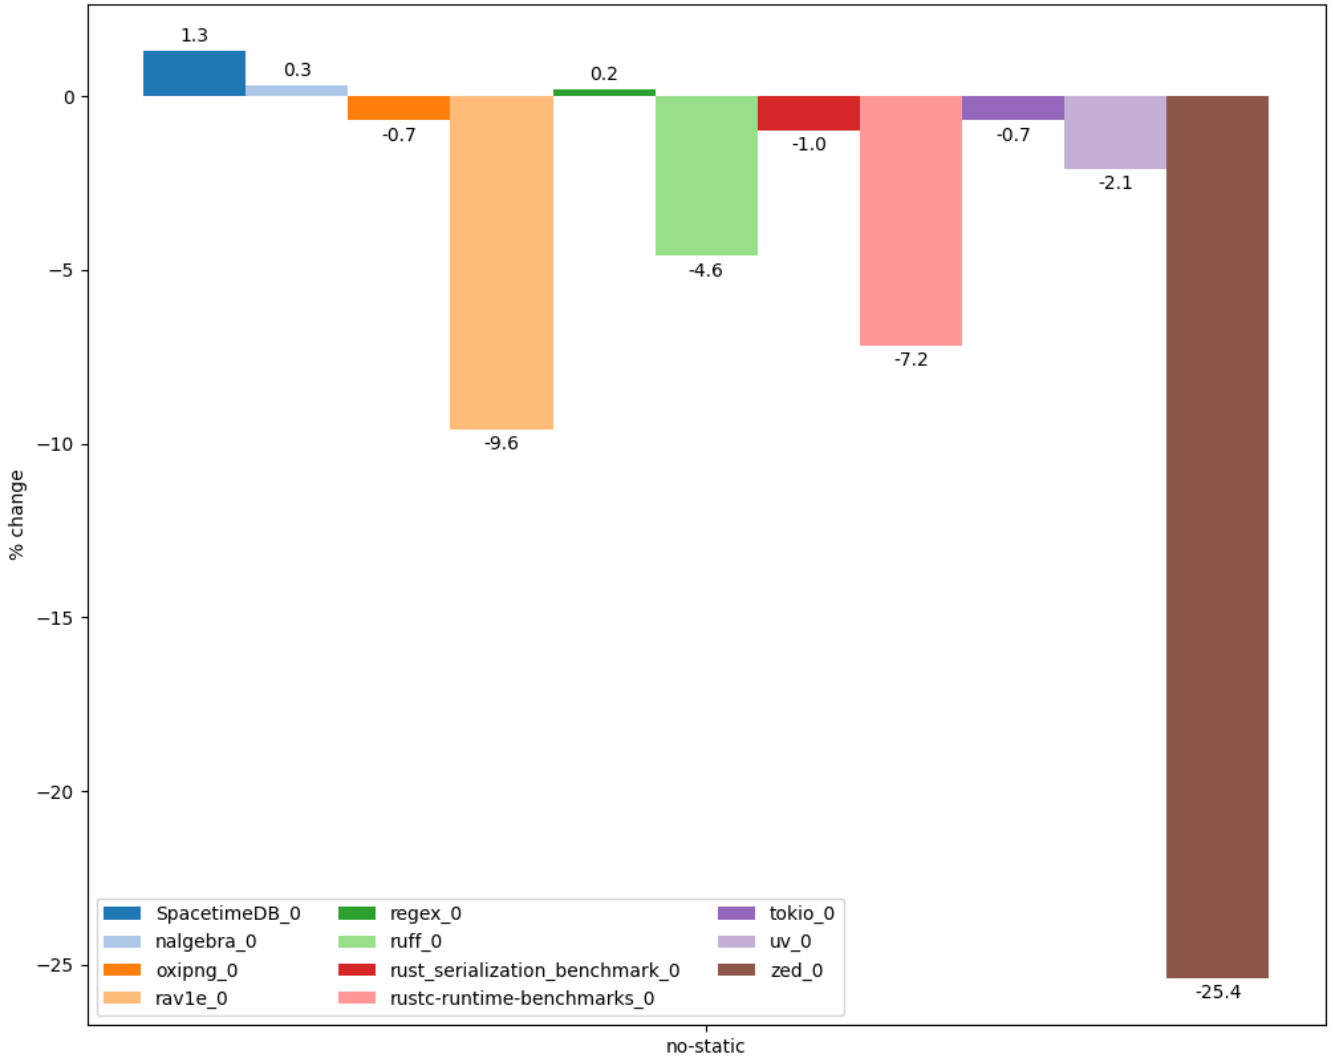

Патч для компилятора

Выводы

- Локализация функций позволяет компилятору генерировать существенно более производительный код (5% и более)
- В Rust по умолчанию принято более эффективное (с точки зрения производительности) решение

Оптимизации расположения полей

Детальный разбор
(пока не готов)

Выравнивание полей структур

- Многие языки (C, C++, C#, Swift) сохраняют порядок полей структуры, указанный в исходном коде
- Для выравнивания адресов полей между ними может добавляться паддинг
  - Выравнивание необходимо из-за аппаратных ограничений
  - Невыровненные обращения могут вызывать исключения или замедление работы
- Выравнивание полей ускоряет доступ к ним, но ухудшает локальность данных в D$

```
struct RandomOrder {
  uint8_t  m_byte1;
  uint64_t m_long;
  uint8_t  m_byte2;
  uint32_t m_int;
  uint8_t  m_byte3;
};
```

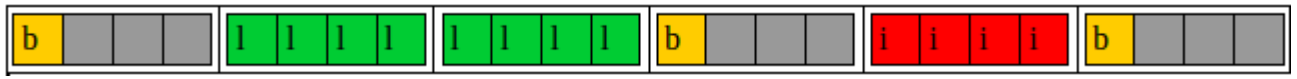

Image source

Структуры в Rust

- Rust ABI не фиксирует порядок полей в структурах
- Это позволяет компилятору свободно его модифицировать
- Оптимизация порядка полей для
  - Снижения D$ pressure (посредством уменьшения требуемого паддинга)
  - Оптимизации расположения ниш (см. ниже)
- В теории компилятор также может размещать вместе поля, которые часто используются вместе
  - Можно воспользоваться PGO или статическим анализом (как -fipa-struct-reorg в GCC)

Оптимизация порядка полей

- Для уменьшения размера поля сортируются в порядке уменьшения выравнивания

```
pub struct Foo {
    pub b: bool,
    pub a: i64,
    pub c: i16,
} // 16 bytes total
```

```
#[repr(C)]
pub struct Foo {
    pub b: bool,
    pub a: i64,
    pub c: i16,
} // 24 bytes total
```

```
#[unsafe(no_mangle)]
pub fn fun(val: Foo) -> i64 {
    val.a
        + (val.b as i64)
        + (val.c as i64)
}
```

```
fun:
  movzx   ecx, byte ptr [rdi + 10]
  add     rcx, qword ptr [rdi]
  movsx   rax, word ptr [rdi + 8]
  add     rax, rcx
  ret
```

```
fun:
  movzx   ecx, byte ptr [rdi]
  add     rcx, qword ptr [rdi + 8]
  movsx   rax, word ptr [rdi + 16]
  add     rax, rcx
  ret
```

Что есть в C++

- Многие статические анализаторы предупреждают о неэффективном расположении полей
  - Clang-tidy, PVS-studio, etc.
  - Pahole (на базе debuginfo)
- clang-reorder-fields – LLVM-based инструмент для перестановки полей для оптимизации паддинга

Устройство Rust enums

- Enums в Rust являются аналогом std::variant в C++
- Могут содержать различные типы данных
  - Конкретный тип определяется в рантайме и хранится в специальном поле – теге
- Объект типа enum содержит
  - Тег с индексом хранимого варианта
  - Данные этого варианта

```rust
pub enum Foo {
    A {x: i32, y: i32},
    B {x: i32, y: i32},
}

#[no_mangle]
pub fn fun(val: Foo) -> i32 {
    match val {
        Foo::A {x, ..} => x,
        Foo::B {y, ..} => y,
    }
}
```

```asm
fun:
  mov     eax, dword ptr [rdi]
  mov     eax, dword ptr [rdi + 4*rax + 4]
  ret
```

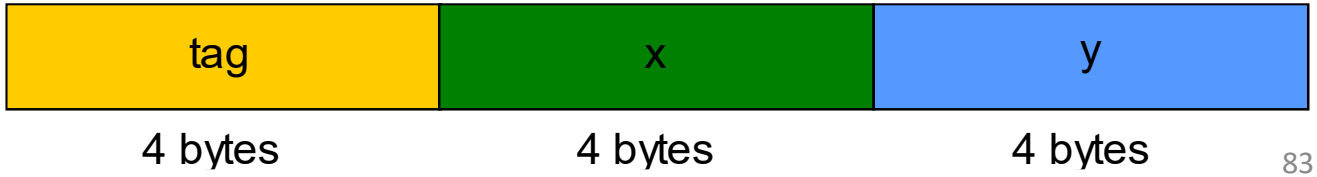

Ниши

- Некоторые комбинации битов могут не соответствовать никакому осмысленному значению кодируемого типа
- Например
  - &x или NonZero<i32> не могут быть нулями
  - bool (8 бит) это только 0b0 или 0b1
    - Остальные 254 значения некорректны
  - char (32 бита) может иметь значения только в диапазонах [0x0, 0xD7FF] и [0xE000, 0x10FFFF]
- Такие невалидные значения называются нишами (niche)
- Могут использоваться для хранения тега enum-типа (вместо отдельного поля)

Примеры нишей

- Самый яркий пример оптимизации ниш – тип Option<T>, где T – NonNull тип (например &U)
  - Оптимизация гарантируется языком
  - Вариант None кодируется нулём, а Some(val) остальными значениями T
  - size_of::<Option<&i64>>() == size_of::<&i64>() == 8
- Аналогичная оптимизация возможна для младших бит ссылки (или указателя)
  - У выровненных указателей несколько младших бит всегда 0
  - Их можно использовать как нишу
  - Пока реализовано только в nightly (-Zreference-niches, rust #3204)

Что есть в C++

- В std::optional нет аналога оптимизаций ниш !
- llvm::PointerIntPair
  - Использует младшие биты указателя для хранения значений int
  - Аналог -Zreference-niches в Rust

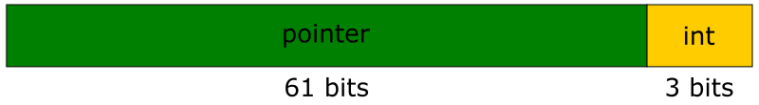

- Lock-free реализации atomic shared_ptr (e.g. в Folly) используют свободные биты адреса для хранения reference count
  - Это позволяет использовать атомарные инструкции меньшей ширины

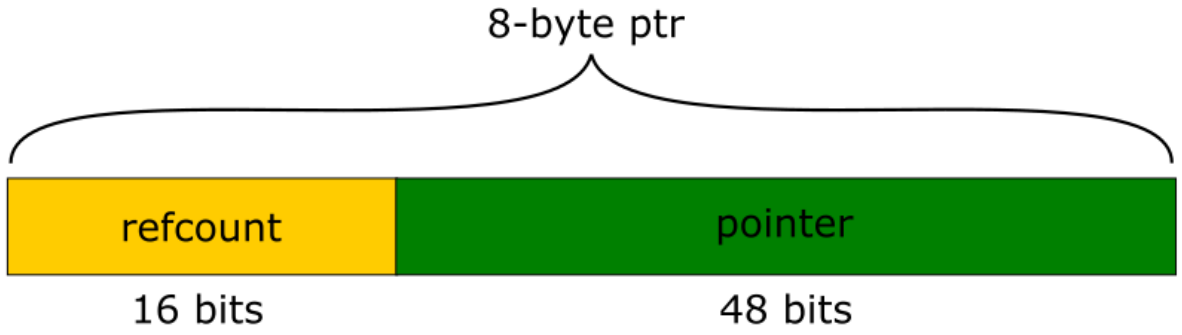

Накладные расходы

- TODO

Выводы

- Rust не гарантирует порядок полей внутри структур
  - Это даёт свободу оптимизаций
  - Но требует осторожности в unsafe коде
- Это позволяет компилятору агрессивно переупорядочивать поля и переиспользовать их для тегов
  - Аналогичные оптимизации можно вручную реализовать и в C++

Арифметические проверки

Детальный разбор

Введение

- Переполнение арифметических операций может приводить к серьёзным системным сбоям
  - ~1% CVE и 1.5% KEV в 2024
  - 23 место в рейтинге Mitre CWE Top 25 2024 (8 в рейтинге 2019 года)
- Наиболее известные примеры:
  - Инцидент с облучателем Therac-25 (1985)
  - Катастрофа ракеты Ariane 5 (1996)
- История (pre-Rust):
  - `-ftrapv` появилась в GCC в 2000 (patch for -ftrapv option)
    - За фичей не следили и она быстро протухла (например BZ #35412 открыт в 2008)
  - Работы John Regehr в 2010 (IOC)
  - Создание UBsan в 2014 (на волне популярности Asan)
    - State-of-the-art решение
- Дополнительная информация:
  - Hardening: текущий статус и перспективы развития

J.R. Armstrong, Famous Failures Revisited

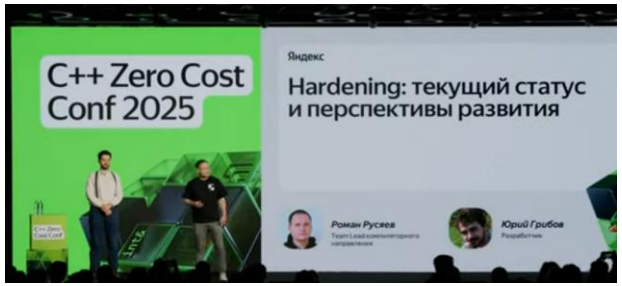

Пример ошибки (OpenSSH 3.3)

```
nresp = packet_get_int();
if (nresp > 0) {
  // Переполняем целое число до нуля здесь ...
  response = xmalloc(nresp*sizeof(char*));
  // ... и вызываем heap buffer overflow тут
  for (i = 0; i < nresp; i++)
    response[i] = packet_get_string(NULL);
}
```

Дефолтные арифметические проверки Rust

- Некоторые (не самые опасные...) арифметические проверки включены по умолчанию
- Деление на ноль
- Знаковое переполнение при делении (INT_MIN / -1)
- Ограничение диапазона при преобразовании float в integer
  - Можно отключить с помощью -Zsaturating-float-casts=off
- Целочисленные переполнения в контейнерах стандартной библиотеки
  - С помощью assert!, checked_add, etc.

Важные проверки, отсутствующие в Rust

- По историческим причинам некоторые важные проверки отсутствуют
  - И даже не могут быть включены по опции
- Например переполнение при преобразовании типа с помощью as
  - Нужно пользоваться альтернативным API try_into/ try_from

```rust
use std::convert::TryFrom;

fn main() {
    if cfg!(try_from) {
        i8::try_from(0x100i32).unwrap();
    } else {
        0x100i32 as i8;
    }
}
```

```
$ rustc +baseline test.rs -O
$ ./test
0
$ rustc +baseline --cfg try_from test.rs -O
$ ./test

thread 'main' panicked at tmp57.rs:5:32:
called `Result::unwrap()` on an `Err` value:
TryFromIntError(())
```

Проверки переполнений в Rust

- По умолчанию целочисленные переполнения в пользовательском коде проверяются *только* в debug-сборках
- Two’s complement в release
- Можно включить проверки по опции -C overflow-checks=on
- Причины: слишком большие накладные расходы
  - “Plan is to turn on checking by default *if* we can get the performance hit low enough and also that it should leave room in the future to move towards universal overflow checking if it becomes feasible” (Niko Matsakis, ко-lead Rust language design team)

Накладные расходы

- Накладные расходы от проверок:
  - Сравнение + предсказуемый условный переход (2 такта конвеера + I$/BTB pressure)
  - Мешают другим оптимизациям (vectorizer, etc.)
- С первым (менее важным) пунктом *возможно* могла бы помочь аппаратная поддержка проверок в процессоре

```rust
#[no_mangle]
pub fn foo(xs: &[i32]) -> i32 {
    let mut ans = 0;
    for x in xs {
        ans += x;
    }
    ans
}
```

```
$ rustc ... test.rs
...
.LBB0_5:
        // Цикл успешно векторизуется
        movdqu  xmm2, xmmword ptr [rdi + 4*rax]
        paddd   xmm0, xmm2
        ...
$ rustc ... -Coverflow-checks=on test.rs
...
.LBB0_3:
        // Цикл не векторизуется
        add     eax, dword ptr [rdi + rcx]
        jo      .LBB0_6
        add     rcx, 4
        cmp     rsi, rcx
        jne     .LBB0_3
        ...
```

Defined overflow

The Value of Undefined Behavior и Garbage In, Garbage Out

- В отличие от C/C++ целочисленное переполнение не является Undefined Behavior
  - Паника или Two’s complement
- Это лишает оптимизатор дополнительной информации
- Может помешать точности анализов (особенно ScalarEvolution) и оптимизаций в LLVM
  - См. также How undefined signed overflow enables optimizations in GCC

```
// Для знаковых i1/i2 компилятор
// может оптимизировать
// индуктивные переменные
// для &buf[i1] и &buf[i2].
// Для беззнаковых нет.

T i1 = 0, i2 = 0;

for (;;) {
    int c1 = buf[i1];
    int c2 = buf[i2];
    if (c1 != c2)
        return c1 - c2;
    i1++;
    i2++;
}
```

Улучшение при отключении дефолтных проверок (деление на ноль и т.д.)

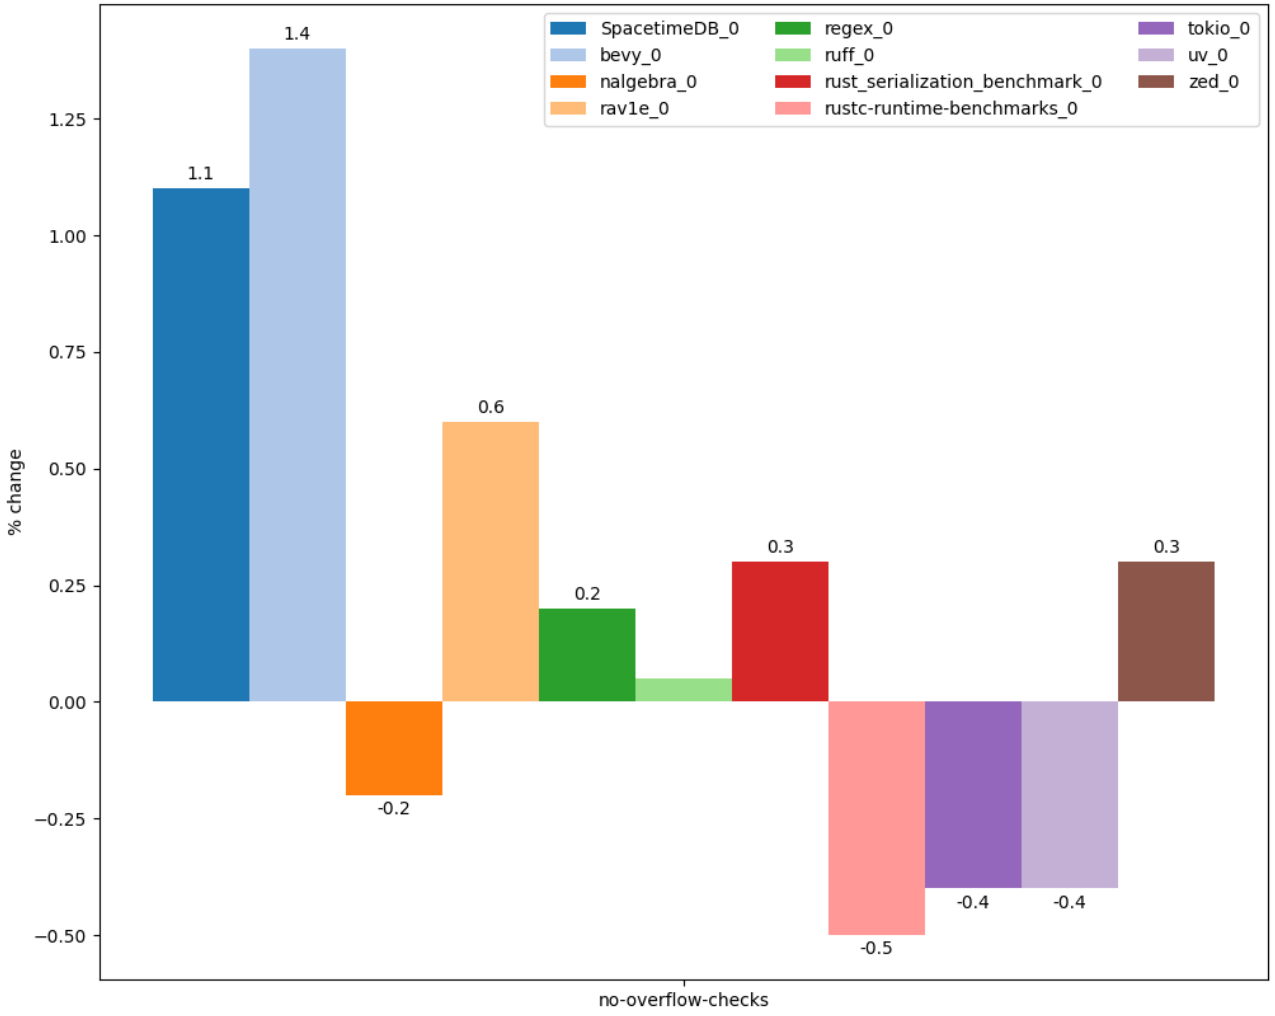

Ветка компилятора

Замедление при включении целочисленных переполнений

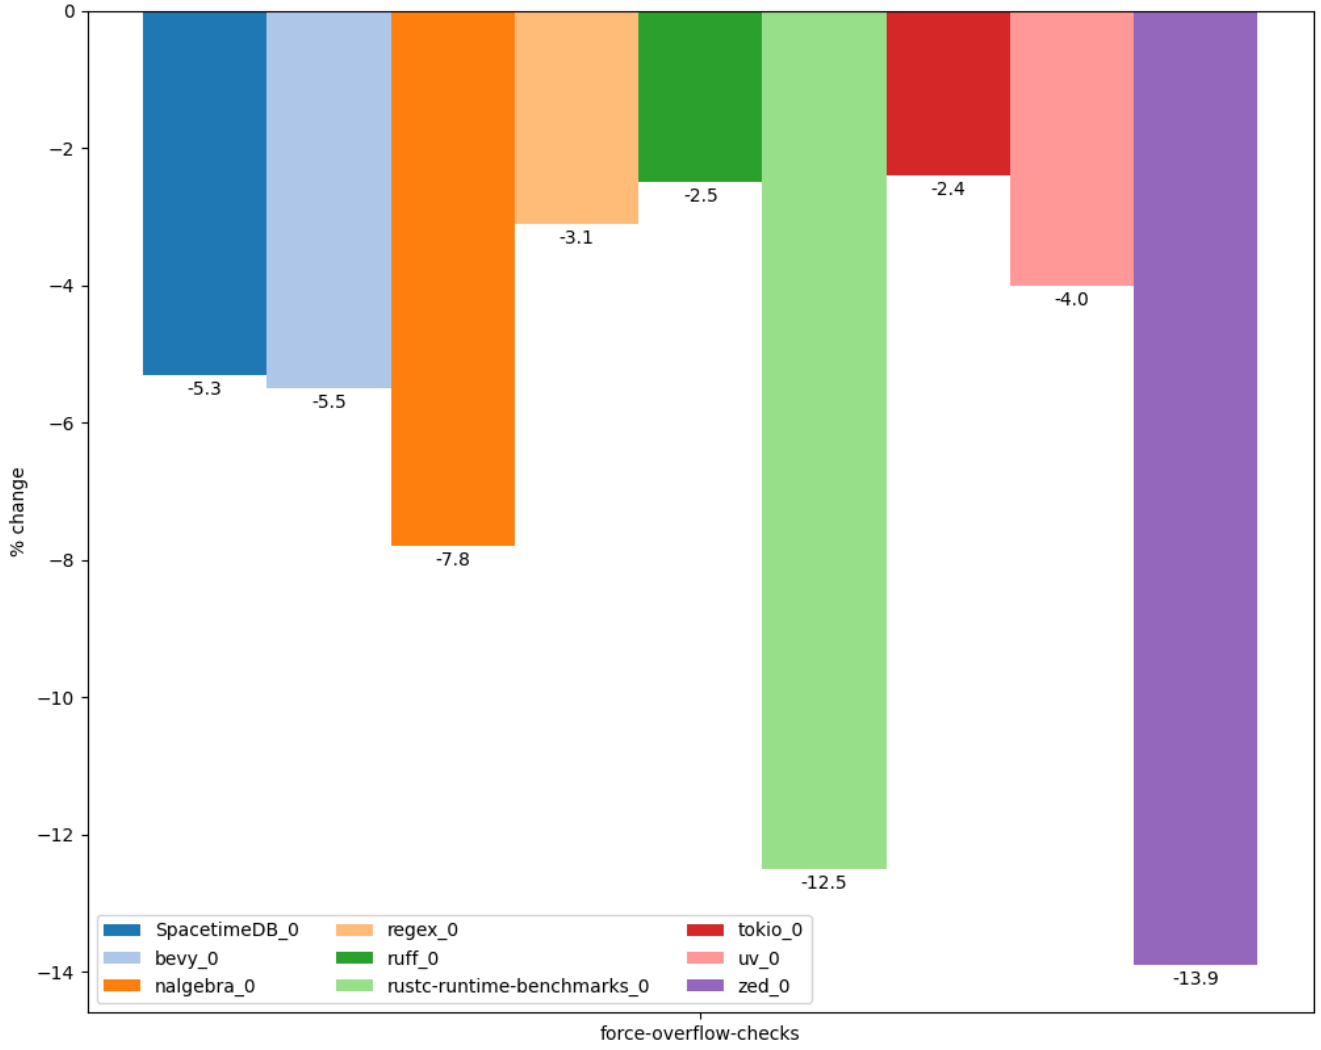

- Существенный рост числа проверок (+30% проверок в rustc)

Ветка компилятора

Замедление в C++

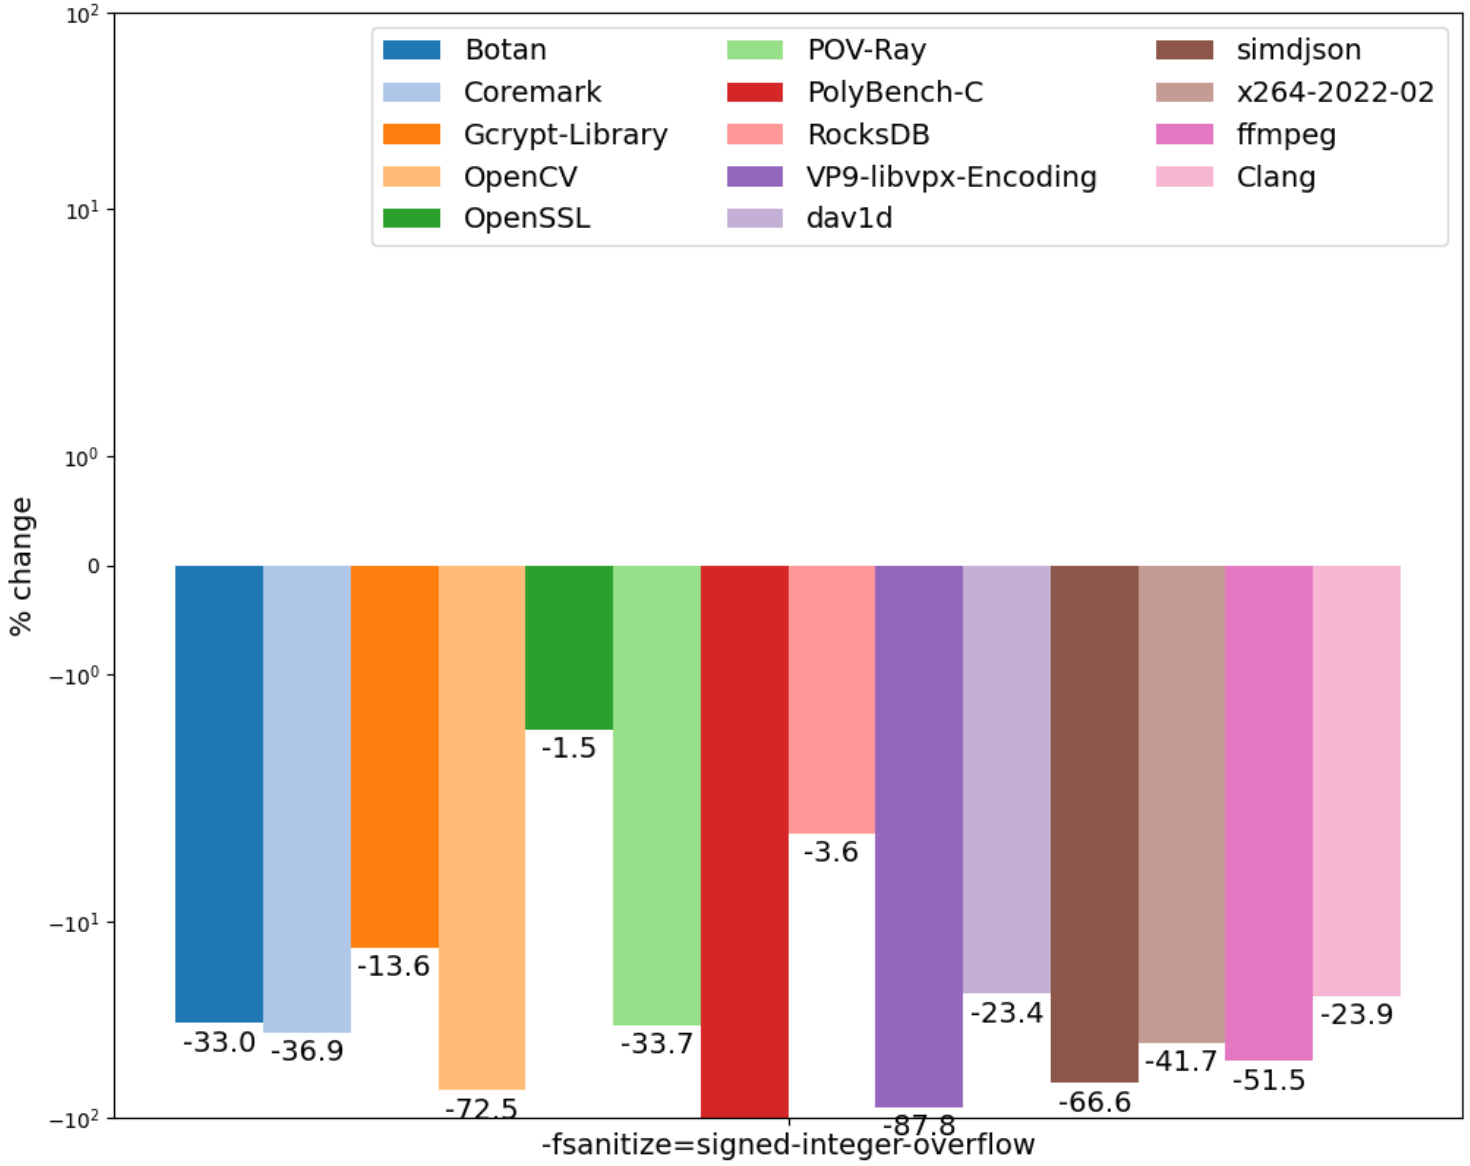

- Аналогичный или даже б*ольш*ий оверхед в UBsan для C/C++

Оптимизации в компиляторе

- Проверки переполнений намного хуже оптимизируются компилятором
  - Арифметика Пресбургера разрешима, но имеет сложность O(2^2^N)
- При сборке stage 2 rustc компилятор оптимизирует ~30% арифметических проверок
  - Данные получены на основе анализа бинарного кода

Workarounds

- Небезопасные API для арифметики:
  - unchecked_add, wrapping_add, etc.
  - to_int_unchecked
  - core::hint::unreachable_unchecked

```
if x <= i32::MIN >> 1 || x >= i32::MAX >> 1 {
    unsafe { std::hint::unreachable_unchecked() }
}
x * 2 / 2
```

  - (проверки в стандартной библиотеке *не могут* быть отключены)
- Специальные типы стандартной библиотеки:
  - NonZeroU32 для отключения некоторых проверок деления
  - Wrapping<T> для переполнений

Выводы

- В Rust целочисленное переполнение не является UB
  - Мешает компилятору проводить некоторые агрессивные оптимизации
- В языке приняты неочевидные решения о дефолтных арифметических проверках
  - Действительно важные ошибки типа приведения с потерями не проверяются, зато проверяется деление на ноль
  - Могут давать замедление ~1%
- Целочисленные переполнения имеют слишком большие накладные расходы (до 10%)
  - Аналогично UBsan
  - Вряд ли будут включены по умолчанию в будущем

Стандартная библиотека

Детальный разбор

Введение

- По сравнению с STL в стандартной библиотеке Rust делается больше обязательных проверок и используются более устойчивые (и медленные) алгоритмы
  - За счёт встроенной системы сборки Cargo в Rust легко экспериментировать с альтернативными реализациями
- Но в некоторых ситуациях могут использоваться более быстрые контейнеры и алгоритмы (по сравнению с STL)

Проверки в стандартной библиотеке

- Стандартная библиотека Rust содержит большое количество неотключаемых проверок (assert!, checked_add, etc.)
- Основные виды проверок:
  - Корректность индексов в контейнерах (bounds checks, уже рассматривались выше)
  - Отсутствие переполнений при аллокациях (capacity overflow)
  - Успешность аллокаций памяти в контейнерах
  - Корректные обращения к UTF-8 контейнерам &str и String
  - API-специфичные проверки (аксиомы компараторов, etc.)
- Некоторые аналогичные проверки доступны и в STL
  - По макросам _GLIBCXX_ASSERTIONS и _LIBCPP_HARDENING_MODE (Hardened STL)

Пример

```rust
pub fn foo(length: usize) -> Vec<i32> {
    vec![-1; length]
}
```

```
        lea     r15, [4*rsi]
        xor     r13d, r13d
        mov     rax, rsi
        // Проверяем что 4*length не переполняется
        shr     rax, 62
        jne     .LBB0_11
        // Проверяем что 4*length <= isize::max
        movabs  rax, 9223372036854775804
        cmp     r15, rax
        ja      .LBB0_11
        ...
        // Проверяем успешность аллокации
        call    qword ptr [rip +
_RNvCslKhMTRUAIjP_7___rustc12___rust_alloc@GOTPCREL]
        test    rax, rax
        je      .LBB0_11
```

Пример

```rust
use std::io;

fn main() {
    let mut input = String::new();
    io::stdin()
        .read_line(&mut input)
        .unwrap();
    println!("{}", input);
}
```

```
$ echo Привет | ./test
Привет

$ echo Привет | iconv -f UTF-8 -t KOI8-RU | ./test
thread 'main' panicked at test.rs:5:39:
called `Result::unwrap()` on an `Err` value:
Error { kind: InvalidData, message: "stream did not contain valid UTF-8" }
```

Другие накладные расходы

- Дефолтный алгоритм хэширования (SipHash) устойчив к DoS-атакам, но является более медленным чем аналогичные алгоритмы в STL
  - 2x замедление по сравнению с fxhash на простом микробенчмарке
- Ввод-вывод в Rust по умолчанию не буферизуется
  - Без использования BufReader программы могут работать в десятки раз медленней
- io::stdout() строчно-буферизуем даже для не-TTY вывода (rust #60673)
  - Это может сильно замедлять command-line утилиты (в ситуциях типа “./prog > file”)
- Макросы print!/println! используют монопольный доступ для обеспечения корректного выводы из параллельных потоков

Улучшение при отключении проверок UTF-8

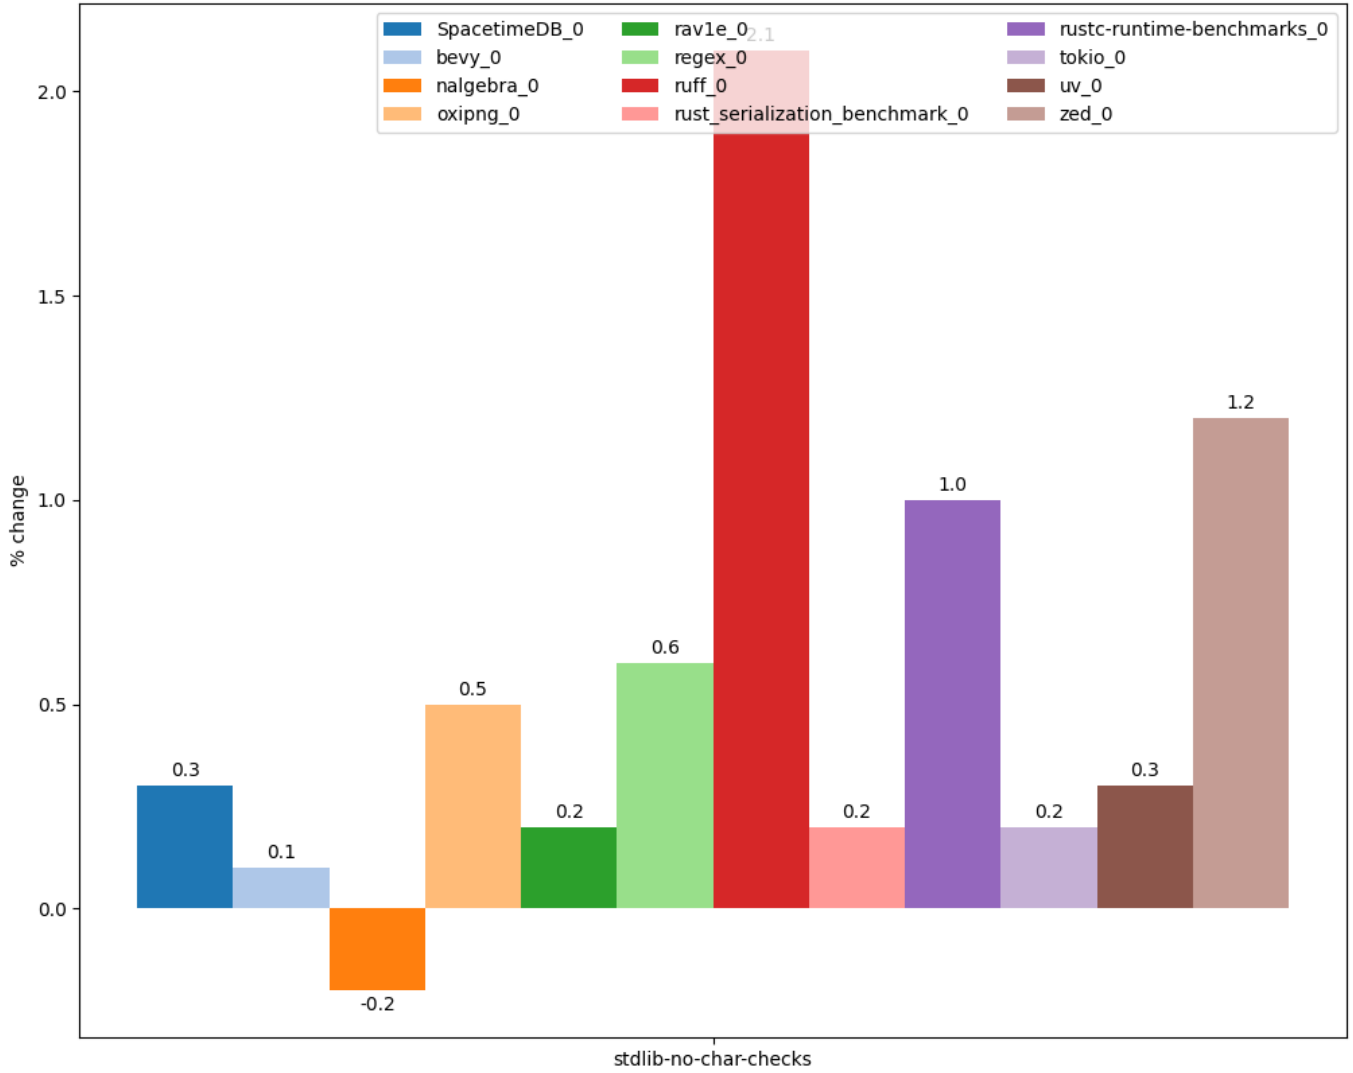

Ветка компилятора

Улучшение при отключении проверок переполнений в контейнерах

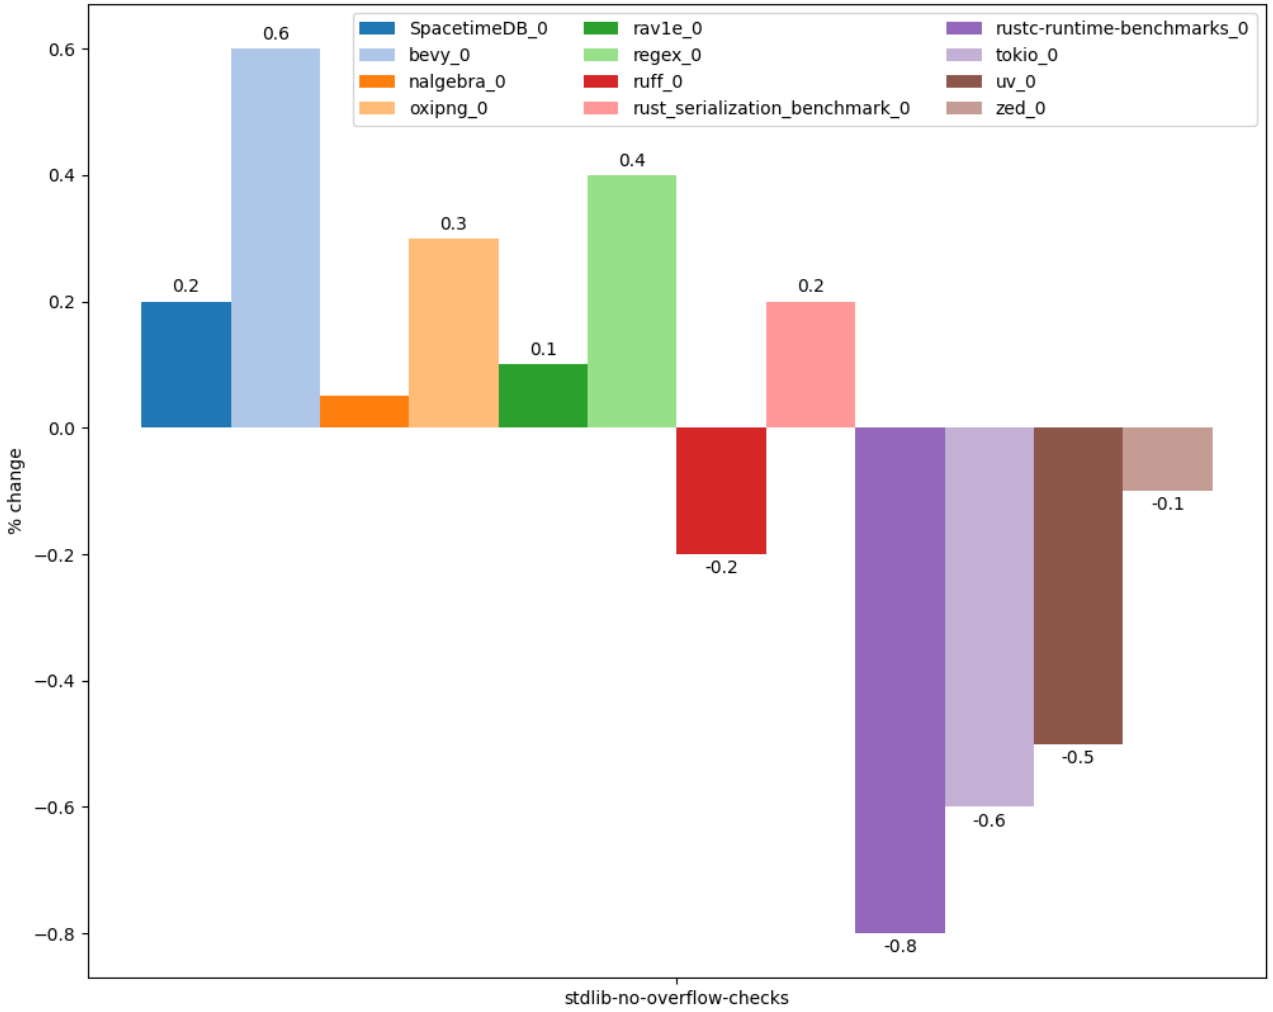

Ветка компилятора

Оптимизации в стандартной библиотеке

- Хэштаблицы:
  - Нет требования валидности ссылок после изменения таблицы (как в std::unordered_map)
  - Это позволяет использовать open-addressing вместо chaining (меньше аллокаций, cache-friendly)
- В деревьях поиска используется B-tree (вместо RB-tree как в std::map)
  - Меньше аллокаций, cache-friendly
  - 4x ускорение на простом микробенчмарке
- Современные ILP-friendly алгоритмы сортировки (ipnsort, driftsort)
  - STL-алгоритмы написаны для упрощения векторизации при сортировке примитивных типов
  - 65% ускорение на простом микробенчмарке

Выводы

- В стандартной библиотеке языка есть как факторы, негативно влияющие на производительность, так и более эффективные (по сравнению с STL) алгоритмы и контейнеры
- Недостатки стандартной библиотеки не критичны из-за
  - Наличия большого числа альтернативных реализаций
  - Простоты интеграции внешних библиотек в инфраструктуре Cargo

Отсутствие режима fast-math

Детальный разбор

Вычисления с плавающей запятой

- Стандарт IEEE 754
  - Типы и их представление
  - Операции над ними
  - Округление
- Большинство архитектур, языков и компиляторов следуют стандарту (почти полностью)
- Причины расхождений
  - Аппаратная специфика
  - Больше возможностей для оптимизации
- fast-math – собирательный термин для оптимизаций, связанных с ослаблением требований IEEE 754

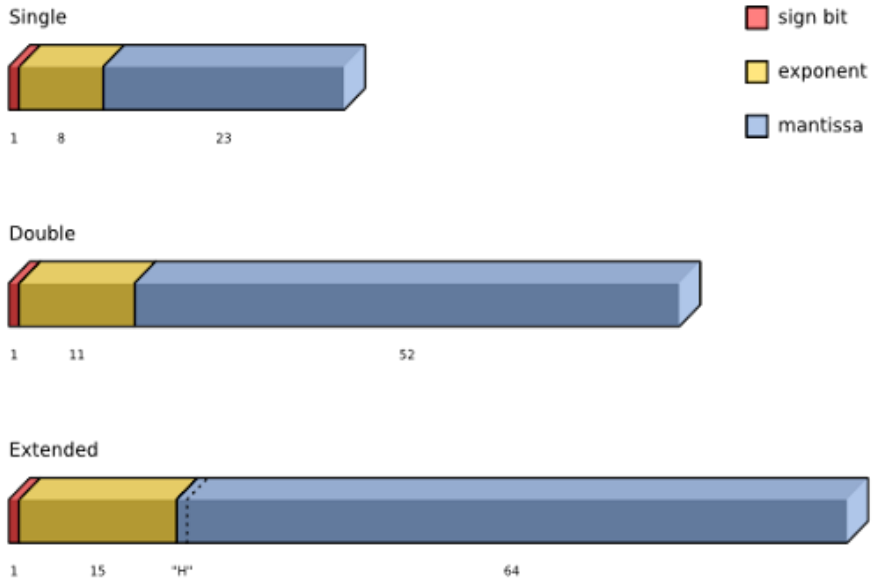

Виды fast-math флагов

- Алгебраические:
  - Ассоциативность
  - Беззнаковость нуля
  - Замена деления на умножение
  - Объединение операций (например FMA)
- Запрет нестандартных значений:
  - NaN, Infinity

```
double foo(double val) {
  return (val + 3.0) / 3.0;
}
```

```
.LCPI0_0:
        .quad   0x4008000000000000 # 3.0
foo:
        movsd   xmm1, qword ptr [rip +
.LCPI0_0]
        addsd   xmm0, xmm1
        divsd   xmm0, xmm1
        ret
```

clang-21 -O2

```
.LCPI0_0:
        .quad   0x4008000000000000 # 3.0
.LCPI0_1:
        .quad   0x3fd5555555555555 # 1/3
foo:
        addsd   xmm0, qword ptr [rip +
.LCPI0_0]
        mulsd   xmm0, qword ptr [rip +
.LCPI0_1]
        ret
```

clang-21 -O2 -freciprocal-math

Как на это смотрят языки программирования

- У разных языков различные отношения к соблюдению IEEE 754
- Стандарт C запрещает fast-math оптимизации (в Annex F)
  - Но обычно их можно включить с помощью флагов (например -ffast-math)
  - Часто используется в игровых движках
- Аналогичное поведение для языка Swift
- Java и C# разрешают совершать вычисления с б*о*льшей точностью, чем результирующий тип
- Go разрешает объединение операций
  - Но только если этому не препятствуют явные преобразования типов
- Fortran явно разрешает нарушать IEEE 754 ради производительности

Оптимизации: Векторизация

- -fassociative-math и -fno-signed-zeros позволяет компилятору переупорядочить итерации цикла и векторизовать вычисления

```
#include <math.h>

float sum256(float *arr1, float *arr2) {
  float s;
  int i;
  s = 0.0f;
  for (i = 0; i < 256; i++) {
    s += arr1[i] * arr2[i];
  }
  return s;
}
```

```
.LBB0_1:
  movss   xmm1, dword ptr [rdi + 4*rax]
  mulss   xmm1, dword ptr [rsi + 4*rax]
  addss   xmm0, xmm1
  # один элемент за итерацию цикла
  inc     rax
  cmp     rax, 256
  jne     .LBB0_1
```

clang-21 -O2 -fno-unroll-loops

```
.LBB0_1:
  movups  xmm1, xmmword ptr [rdi + 4*rax]
  movups  xmm2, xmmword ptr [rsi + 4*rax]
  mulps   xmm2, xmm1
  addps   xmm0, xmm2
  # 4 элемента за итерацию цикла
  add     rax, 4
  cmp     rax, 256
  jne     .LBB0_1
```

clang-21 -O2 -fno-unroll-loops
-fassociative-math -fno-signed-zeros

Оптимизации: Finite only

- -ffinite-math-only разрешает оптимизации, основанные на том, что операнды не принимают NaN или Inf значений
- Это позволяет:
  - Удалять проверки на NaN и Inf
  - x == x => true
  - x / x => 1
- А с -fno-signed-zeros:
  - x – x => 0
  - 0 / x => 0
  - x * 0 => 0

```
bool foo(double val) {
  return val == val;
}
```

```
foo:
  ucomisd xmm0, xmm0
  setnp   al
  ret
```

clang-21 -O2

```
foo:
  mov     al, 1
  ret
```

clang-21 -O2
-ffinite-math-only

```
double foo(double val) {
  return val * 0;
}
```

```
foo:
  xorpd   xmm1, xmm1
  mulsd   xmm0, xmm1
  ret
```

clang-21 -O2

```
foo(double):
  xorps   xmm0, xmm0
  ret
```

clang-21 -O2
-ffinite-math-only
-fno-signed-zeros

Подводные камни: Проверки

- Появление Inf или NaN значений при использовании -ffinite-math-only приводит к UB
- Если отсутствие этих значений обеспечивалось явными проверками, то они будут удалены компилятором

```
#include <math.h>

int foo(float f) {
  return isnan(f);
}
```

```
foo:
  xor     eax, eax
  ucomiss xmm0, xmm0
  setp    al
  ret
```

clang-21 -O2

```
foo:
  xor     eax, eax
  ret
```

clang-21 -O2
-ffinite-math-only

Позиция Rust

- Rust отказывается от возможности глобального применения fast-math оптимизаций
- Основная мотивация – опасность недостаточно осторожного применения этих оптимизаций, особенно в зависимостях проекта

> “Everything about this flag fundamentally clashes with the idea of robust, compositional system design. It was a terrible mistake to ever add it to C compilers, and Rust should not repeat that mistake. Rust should instead explore alternative, less fragile ways of exposing those semantics.” (Ralf Jung, rust #21690)

Workarounds: Интринсики

- Rust предоставляет fast-math оптимизации на уровне отдельных операций
  - std::intrinsics::f{op}_fast
  - std::intrinsics::f{op}_algebraic
  - f(16/32/64)::algebraic_{op}
- Недостатки:
  - На данный момент эти API недоступны в стабильной версии
  - На данный момент нет типов, скрывающих внутри себя работу с интринсиками
    - Авторам математических библиотек придётся реализовывать код дважды (для fast-math и обычного варианта)

Результаты при включении fast-math

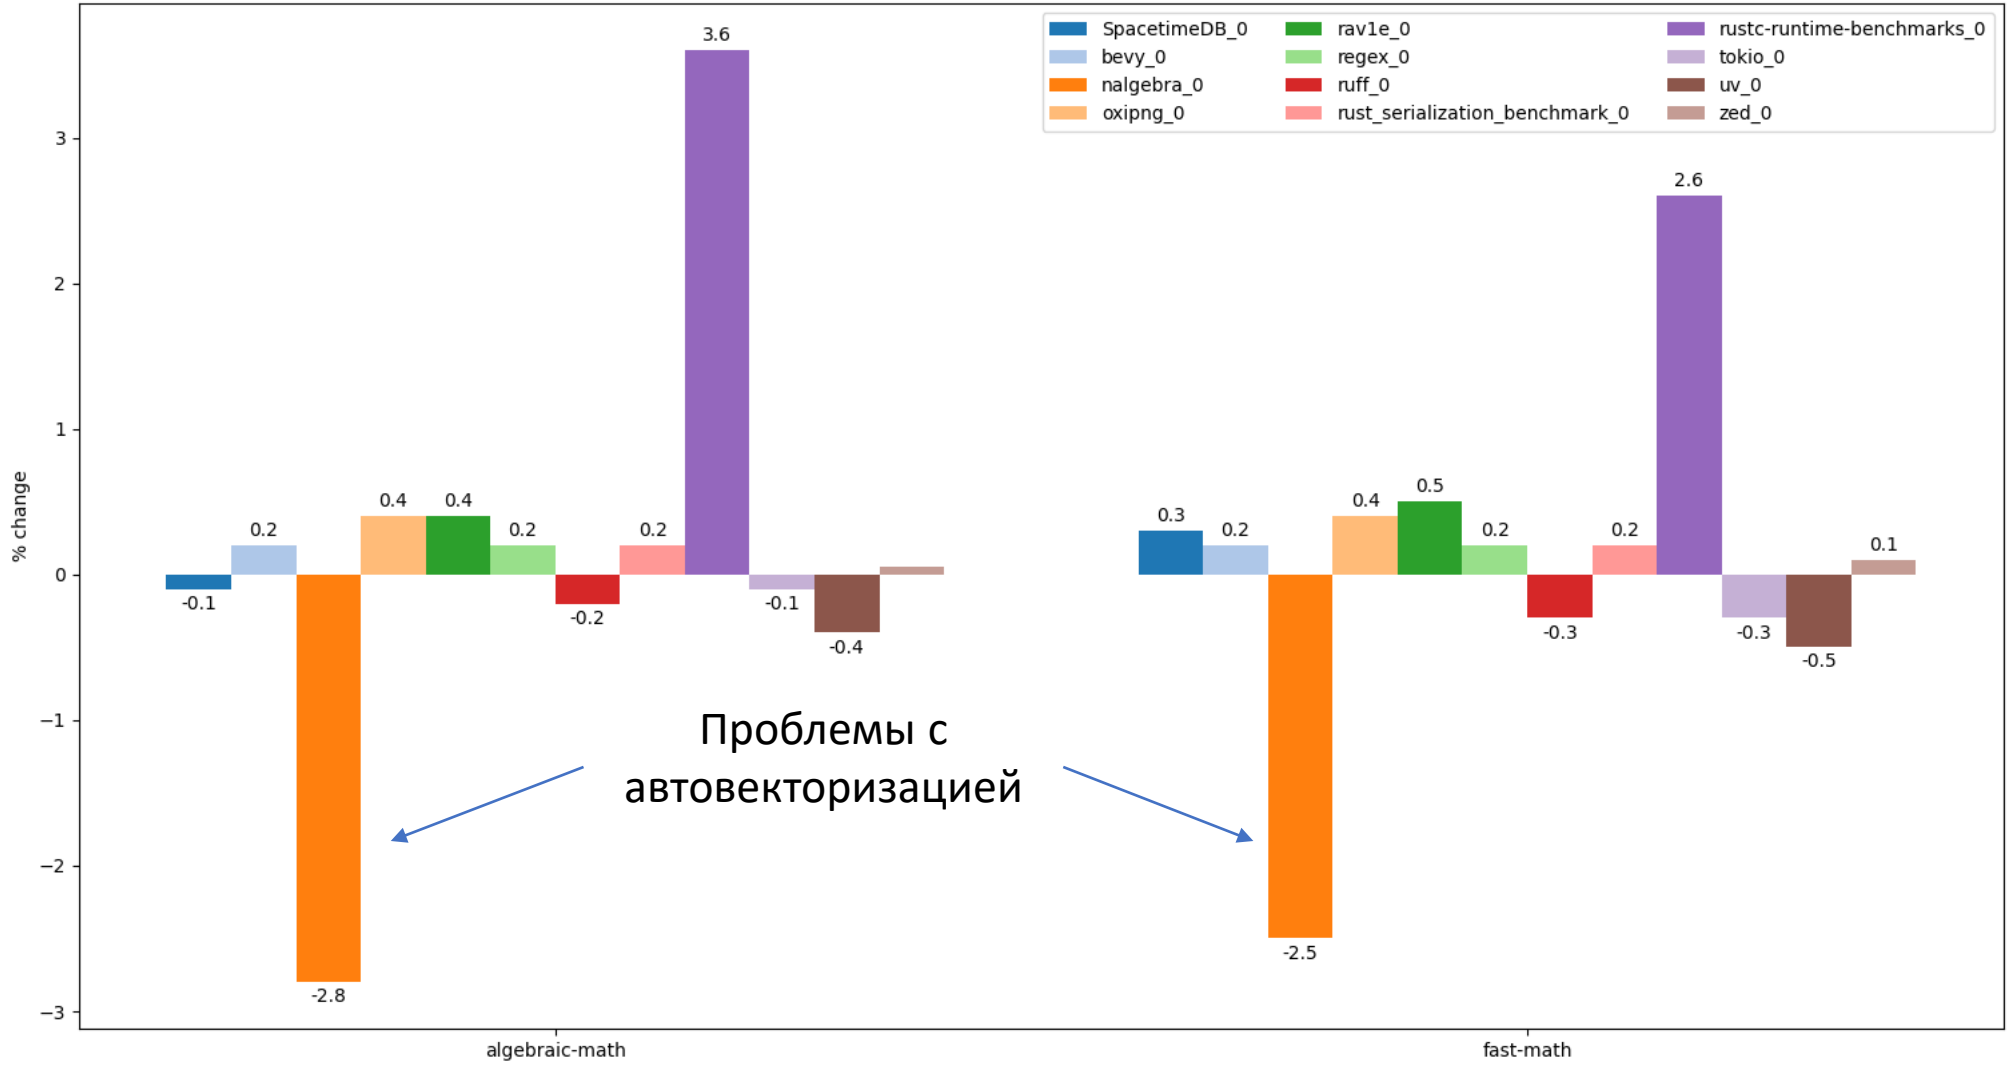

[Ветка компилятора](#) [Ветка компилятора](#)

Выводы

- Rust не предоставляет возможности глобально включить fast-math оптимизации
- Разрешать эти оптимизации можно на уровне отдельных операций с помощью интринсиков
  - Пока только в nightly-версии
- Fast-math может как положительно, так и отрицательно влиять на производительность

Выводы

Ускорение при отключении (почти) всех проверок Rust

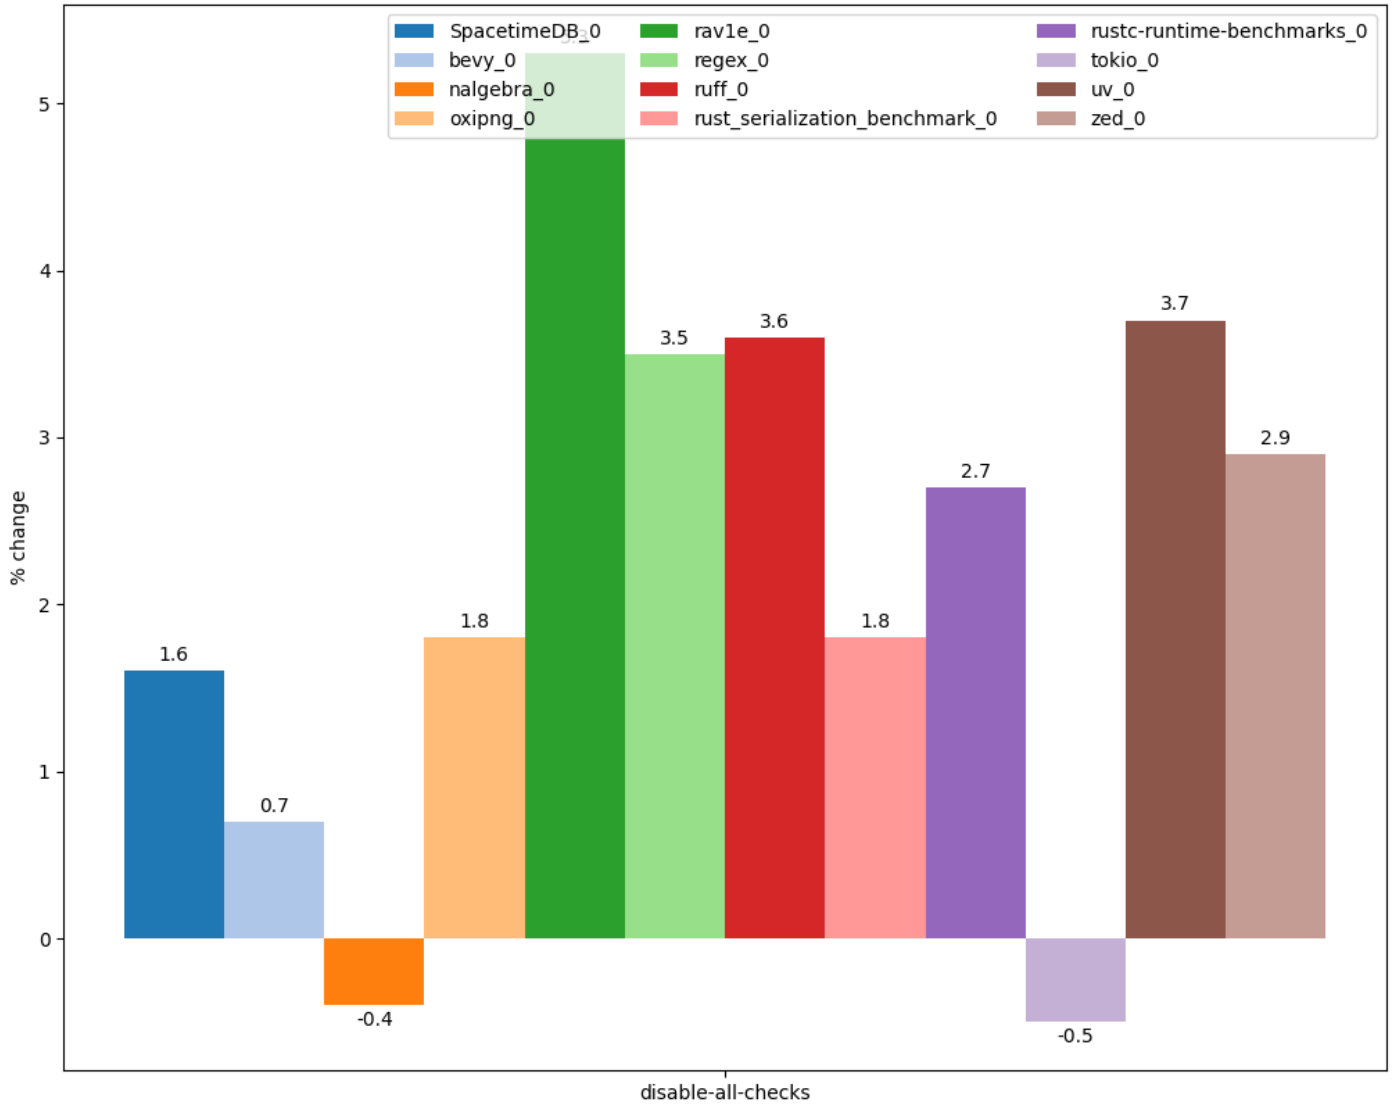

- Отключались проверки индексов, переполнения контейнеров stdlib, проверки UTF-8 в строках
- Не отражены накладные расходы на избыточную инициализацию (полагаем не менее 1%)

Ветка компилятора

Выводы

- Сообщество Rust следит за балансом безопасности и производительности:
  - Бескомпромиссно включаются только проверки memory safety
  - Остальные делаются только если не влияют существенно на производительность
  - Например по умолчанию отключены проверки integer overflow
- Оверхед динамических проверок зависит от проекта и может составлять 3-6%
  - TODO: сравнить с Hardened C/C++ ?
- Факторы, наиболее существенно влияющие на производительность программ:
  - Индексные проверки, автоинициализация, отсутствие inplace-инициализации
- Скорее всего будут оптимизироваться в будущих версиях Rust и LLVM
- Но полностью их негативное влияние обойти нельзя (по крайней мере в текущей версии языка)
- Всегда будут требовать тюнинга и неидиоматичного кода для достижения оптимальной производительности

О чём мы не успели рассказать ...

- Отсутствие inplace-инициализаций
  - Доступна в полной презентации
- Codegen units
- Особенности реализации паник (исключений)
  - В целом накладные расходы аналогичны исключениям в C++
- GC-sections by default
- Особенности ABI
- Отключение PLT
- Особенности реализации виртуальных методов
- Проверки Stack Clashing

Вопросы ?

Выражаем благодарность нашим рецензентам:

- Вадим Петроченков
  - https://github.com/petrochenkov
- Александр Чичигин
  - https://github.com/Gabriel-Fallen
- Jakub Beránek
  - https://github.com/kobzol
- Александр Монаков
  - https://github.com/amonakov
  - https://codeberg.org/amonakov
- Тимур Сафин
  - https://github.com/tsafin

Последняя версия слайдов: https://github.com/yugr/rust-slides/blob/main/RU.pdf

Подготовка доклада

- Собрано и проанализировано более 350 статей, блогпостов и обсуждений по теме доклада из разных источников (materials)
- Общие временные затраты на подготовку (на февраль 2026):
  - > 3 человекомесяцев
- Анализ проводился для
  - Rust 1.87.0 (май 2025)
  - Clang llvmorg-20.1.7 (июнь 2025)

Rust-бенчмарки

- Для сравнения использовались стандартные Criterion-бенчмарки каждого проекта (cargo bench), усреднённые с помощью geomean
  - Некоторые особо медленные тесты в oxipng были отключены
  - Для борьбы с системными шумами бралось минимальное значение средних из нескольких прогонов
  - Важно: 1% geomean может означать что
    - Все тесты в проекте замедлились на 1%
    - 10% тестов замедлилось на 10% (более вероятно)
  - Отдельные тесты могли замедлиться (или ускориться) на десятки процентов
- Оценка с помощью geomean неидеальна
  - Сценарии с бо*л*ьшим количеством бенчей сильнее влияют на результат
- Дополнительные детали здесь

C++ бенчмарки

- Использовался компилятор Clang версии llvmorg-20.1.7
- Llvm-bench (benchmarks/cpp/llvm-bench)
  - Замерялось медианное время O2-компиляции файла CGBuiltin.cpp (самый большой файл в LLVM) компилятором Clang
  - Тестируемый Clang был собран самим собой
- Ffmpeg-bench (benchmarks/cpp/ffmpeg-bench)
  - По мотивам Stack Smashing Protection and Its Performance Impact
  - Замерялось медианное время конвертации файла FLV в MP4
- Phoronix Test Suite (benchmarks/cpp/PTS)
  - Популярный набор бенчмарков с phoronix-test-suite.com
  - Замерялись бенчмарки botan, bullet, coremark, c-ray, dav1d, gcrypt, gmpbench, luajit, nginx, opencv, openssl, polybench-c, povray, rocksdb, simdjson, vpxenc, x265 (см. #55)
  - Использовалось медианное время работы бенчмарка
  - Игнорировались тесты с Stdev > 0.5% и изменениями < 1%
- Для борьбы с системными шумами бралось минимальное значение медиан из 2-3 прогонов

Тестовый сервер

- Все бенчмарки (кроме no-static) были замерены на Intel Xeon E-2236
  - С частотой зафиксированной на 2 ГГц
  - С установленной Ubuntu 24.04
- Сервера настраивались в соответствии с методологией uInit

Распределение замедлений в бенчмарках

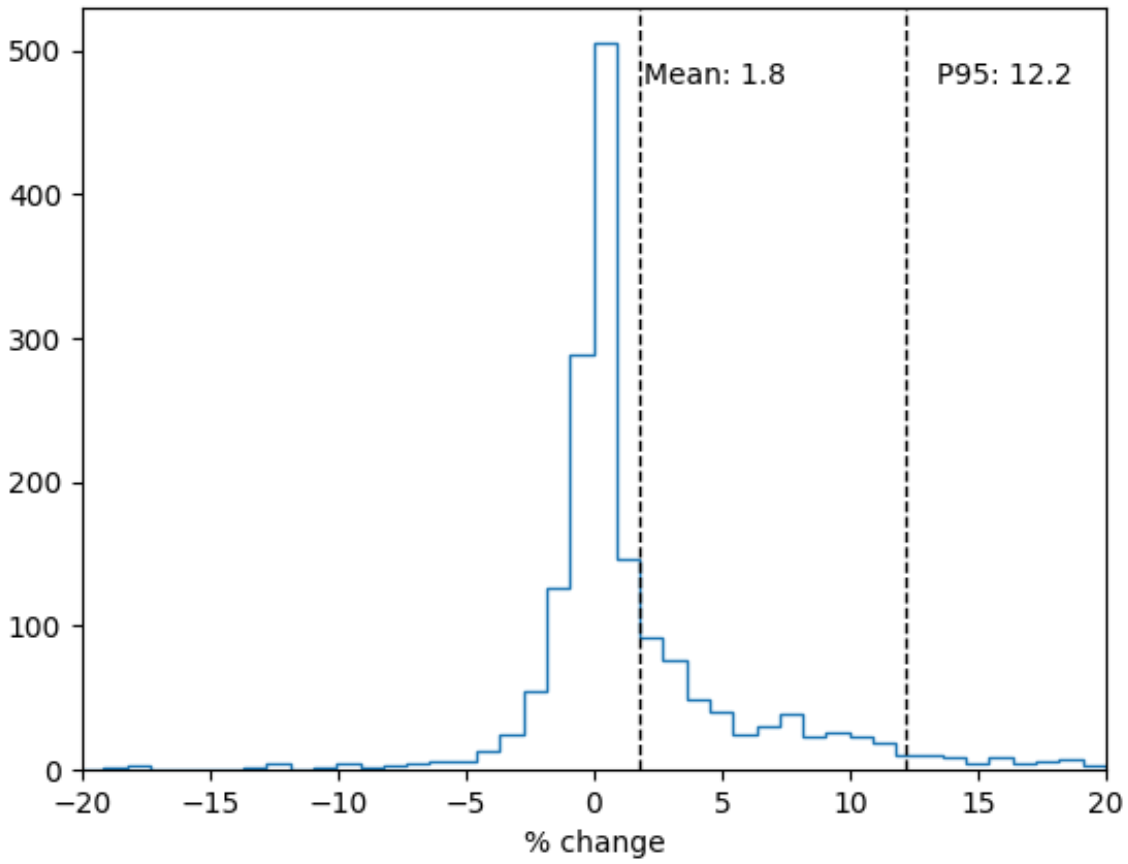

- Собирались данные по всем бенчмаркам всех проектов
- Это **смещённая** оценка:
  - Проекты с б*о*льшим числом бенчей доминируют
  - Сценарии внутри проекта с б*о*льшим числом бенчей доминируют
- Не отражены накладные расходы на инициализацию (не менее 1%)

[Скрипт для построения графиков]

Распределение замедлений в бенчмарках

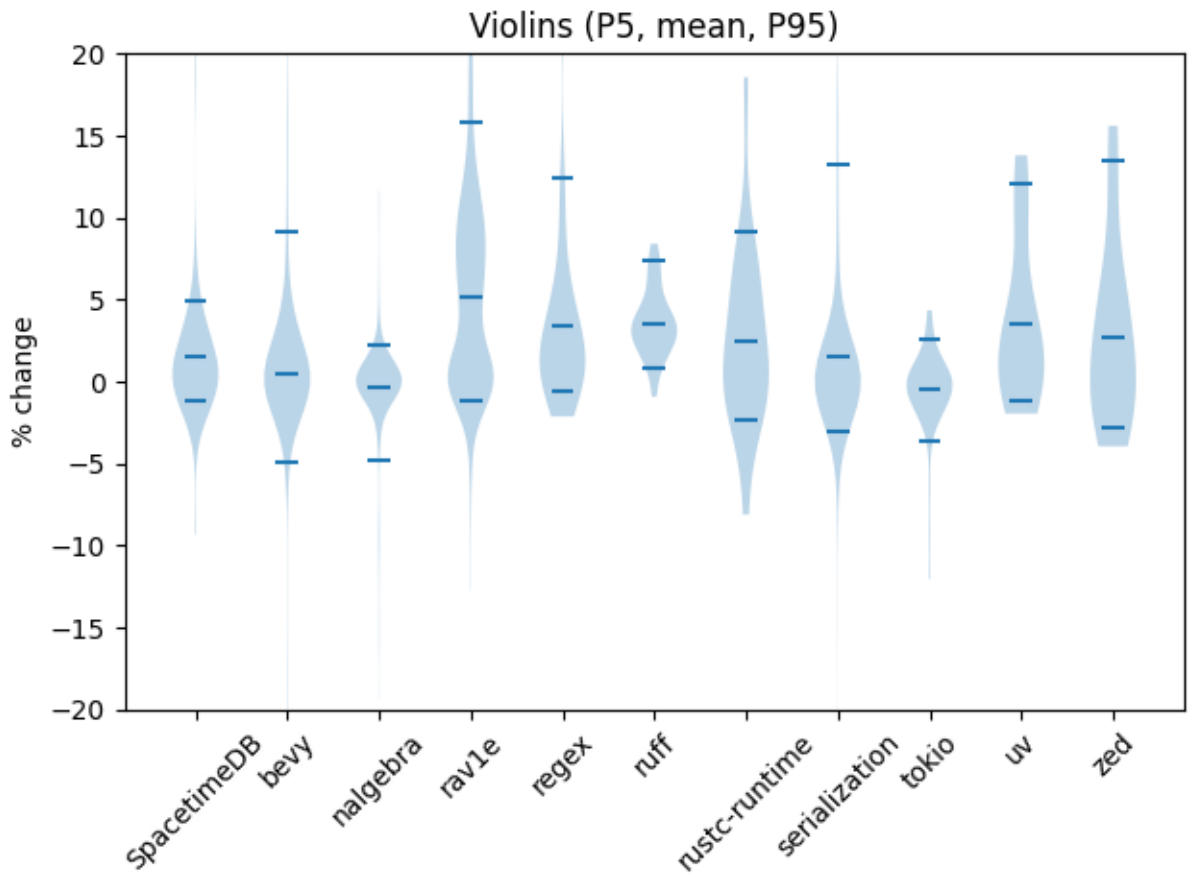

- Собирались данные по всем бенчмаркам внутри каждого проекта
- Это **смещённая** оценка:
  - Сценарии внутри проекта с большим числом бенчей доминируют
- Не отражены накладные расходы на инициализацию (не менее 1%)

[Скрипт для построения графиков]

TODO

- Добавить результаты meilisearch
- Добавить ссылки на Godbolt
- Fast-math: P3715, добавить про -fno-math-errno и -fno-trapping-math
- Улучшить пример workarounds для обязательной инициализации
- Добавить инфу о специфике бенчей (численные вычисления, графы, IO и т.п.)